Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н. Э. Баумана (национальный исследовательский университет)»
(МГТУ им. Н. Э. Баумана)

ФАКУЛЬТЕТ ИУ «Информатика и системы управления»

КАФЕДРА ИУ7 «Программное обеспечение ЭВМ и информационные технологии»

ОТЧЁТ

по лабораторным работам №1–5 и рубежному контролю №1

по дисциплине «Системы искусственного интеллекта»

Тема: «Рекомендательная система ликёров»

Студент ИУ7-11М _____ И. В. Смирнов
(группа) (подпись) (инициалы, фамилия)

Преподаватель _____ Л. Л. Волкова
(подпись) (инициалы, фамилия)

2026 г.

СОДЕРЖАНИЕ

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ . . 4

ВВЕДЕНИЕ **6**

1 Предметная область и датасет (ЛР1) **8**

1.1 Выбор предметной области 8

1.2 Иерархия предметной области 9

1.3 Признаки объектов 10

1.4 Датасет 12

Выводы 13

2 Меры близости (ЛР2) **14**

2.1 Методика выбора мер 14

2.2 Числовые признаки 15

2.3 Бинарные признаки 17

2.4 Мера по таксономии вкуса 17

2.5 Порядковый и номинальные признаки 18

2.6 Обобщающая мера 19

Выводы 22

3 Рекомендательная система (ЛР3) **23**

3.1 Постановка задачи и выбор подхода 23

3.2 PCv1: рекомендации по затравке 24

3.3 PCv2: набор лайков 24

3.3.1 Рассмотренные подходы 24

3.3.2 Сравнение качества подходов 25

3.4 PCv3: лайки и дизлайки 29

3.4.1 Рассмотренные подходы 29

3.4.2 Сравнение качества политик 30

3.5 Объяснение рекомендаций 32

3.6 Пользовательский интерфейс 32

Выводы 35

4 Поиск и объединённая система (ЛР4, РК1) **36**

4.1 Постановка задачи 36

4.2 Выбор фильтров 36
4.3 Проверка корректности ввода 38
4.4 Пустая выдача: «возможно, Вам понравится» 38
4.4.1 Рассмотренные подходы 38
4.4.2 Сравнение стратегий 39
4.5 Объединённая система (РК1) 40
4.5.1 Сценарий работы 40
4.5.2 Функция полезности для фильтрации рекомендаций . 41
4.6 Пользовательский интерфейс 42
Выводы 48

5 Сценарии диалога (ЛР5) 49
5.1 Постановка задачи 49
5.2 Классы вопросов 49
5.3 Вопросы и переформулировки 51
5.3.1 Класс 1. Вопросы о предметной области 52
5.3.2 Класс 2. Вопросы о функциональности системы . . . 52
5.3.3 Класс 3. Вопросы на поиск и рекомендации 53
5.3.4 Класс 4. Вопросы на сравнение двух объектов 54
5.3.5 Класс 5. Вопросы на изменение состава системы . . . 55
5.3.6 Класс 6. Вопросы, на которые нельзя дать ответ . . . 55
5.4 Местозаменители и шаблоны фраз 56
5.5 Опорные слова 57
5.6 Вежливый ответ по шаблону 59
5.7 Проверка опорных слов 60
Выводы 62

ЗАКЛЮЧЕНИЕ 63

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ 65

ОПРЕДЕЛЕНИЯ, ОБОЗНАЧЕНИЯ И СОКРАЩЕНИЯ

РС	рекомендательная система, программа, ранжирующая объекты каталога по предполагаемой полезности для пользователя.
PCv1, PCv2, PCv3 (v1, v2, v3)	версии контентной РС с входом в виде одного объекта-затравки, набора лайков, лайков и дизлайков.
Лайк, дизлайк	явная положительная или отрицательная оценка объекта пользователем.
Близость $\mathrm{sim}(x, y)$	мера сходства двух объектов, $\mathrm{sim} \in [0, 1]$, $\mathrm{sim}(x, x) = 1$.
Расстояние $d(x, y)$	мера различия двух объектов, в работе $d = 1 - \mathrm{sim}$.
Матрица смежности G	матрица $n \times n$ попарных значений меры, $G_{ij} = \mathrm{sim}(o_i, o_j)$.
LCA	от англ. lowest common ancestor, наиболее глубокий общий предок двух узлов дерева.
SMC	от англ. simple matching coefficient, коэффициент простых совпадений Сокала–Миченера.
Таксономия вкуса	авторская иерархия «Ликёры $\to$ L1 $\to$ L2 $\to$ L3», классифицирующая объекты по вкусу.
Группа интересов	подмножество лайков, попарно связанных цепочкой близостей не ниже порога θ.
Затравка	объект, по которому строится список рекомендаций в PCv1.

Функция полезности $U(x)$	взвешенная степень выполнения фильтров поискового запроса объектом x.
recall(N)	доля скрытых отложенных объектов, попавших в первые N позиций выдачи.
coverage(N)	доля групп интересов пользователя, представленных в первых N позициях выдачи.
Опорное слово	основа слова, словосочетание или условие на местозаменители, по которому узнаётся класс вопроса.
Местозаменитель	обозначение места в шаблоне фразы, вместо которого подставляется значение из словаря, например ⟨ликёр⟩.
Переформулировка	другая формулировка того же вопроса с тем же смыслом и классом.
Hit(k)	доля сценариев, в которых искомый объект занял место не ниже k.

ВВЕДЕНИЕ

Рекомендательные системы помогают пользователю выбрать объект из каталога. Перебрать каталог целиком долго, а сформулировать точный запрос трудно. Предметная область работы — ликёры. Эти напитки сильно различаются по вкусу, крепости и сладости. Покупатель обычно описывает желаемое через знакомые ему образцы вроде «что-то вроде Baileys, но не яичное». Поэтому здесь естественно работает **контентный** подход, в котором рекомендации строятся по сходству признаков объектов [1, 2].

Цель работы — разработать рекомендательную систему ликёров. Она должна объединять контентные рекомендации и параметрический поиск. Каждое принятое проектное решение требуется обосновать.

Задачи соответствуют лабораторным работам блока.

— ЛР1. Сформировать датасет и иерархию предметной области. Дерево должно содержать не менее 25 узлов. Признаки нужны разных типов.

— ЛР2. Реализовать и сравнить меры близости для каждого типа признаков. Отдельно нужны мера по дереву и обобщающая мера по всем признакам.

— ЛР3. Построить контентную РС в трёх версиях: по затравке, по лайкам и по лайкам с дизлайками. Нужен пользовательский интерфейс.

— ЛР4. Реализовать параметрический поиск по фильтрам с проверкой ввода. При пустом результате показывается выдача «возможно, Вам понравится».

— РК1. Объединить ЛР3 и ЛР4 в единую систему с общим интерфейсом, фильтрацией рекомендаций и историей запросов.

— ЛР5. Подготовить сценарии беседы для диалоговой системы на ту же тему. Нужны классы вопросов, не менее пяти вопросов каждого класса с двумя-тремя переформулировками, опорные слова классов и вежливый ответ на вопросы, на которые ответить нельзя.

Для каждого этапа в отчёте описано, какие альтернативы рассматривались и почему выбран конкретный вариант. Там, где выбор можно проверить численно, приведены результаты проверки на датасете. Программы проверок входят в репозиторий и воспроизводят все таблицы и рисунки отчёта.

1 Предметная область и датасет (ЛР1)

1.1 Выбор предметной области

Предметная область работы — ликёры. Это сладкие алкогольные напитки на основе спирта, сахара и ароматической основы вроде трав, фруктов, орехов, кофе или сливок. Область выбрана по трём причинам, важным для последующих лабораторных работ.

1. **Естественная иерархия.** Ликёры классифицируются по вкусовой основе, и эта классификация понятна пользователю. Все знают, что такое «амаро», «цитрусовые» и «сливочные». Её можно оформить деревом и использовать в древесной мере близости в ЛР2.

2. **Разнотипные признаки.** У ликёра есть числовые характеристики — крепость, содержание сахара и объём бутылки. Есть бинарные признаки горечи и контакта с деревом, номинальные страна и производитель, а также текстовое описание. Это позволяет выполнить требования ЛР1 к типам признаков и сравнить меры разных типов в ЛР2.

3. **Выбор «по образцу».** Покупатель обычно ориентируется на уже знакомые ликёры. Поэтому проблема холодного старта не возникает. Для рекомендации достаточно одного лайка, и контентный подход здесь естественен [1, 2].

Датасет содержит $n = 30$ ликёров. Объекты подобраны так, чтобы покрыть все ветви иерархии. В каждой группе второго уровня есть не менее двух представителей, поэтому у любого объекта найдётся «родственник» для проверки рекомендаций. Источник значений признаков отмечен в служебном поле `source_quality`. Два объекта заполнены по спецификации производителя, 14 по литературным данным и ещё 14 экспертной оценкой по стилю. Поле не участвует в мерах близости, но показывает, где значения приближённые.

1.2 Иерархия предметной области

Иерархия построена по **вкусовой основе** ликёра и показана на рисунке 1.1. Корень «Ликёры» делится на пять ветвей первого уровня L1. Это травяные, фруктовые, эмульсивные, ореховые и обжаренные ликёры. На втором уровне L2 ветви делятся на 12 групп, а на третьем уровне L3 — на 24 вкусовых листа. К листьям прикреплены 30 объектов с атрибутами из раздела 1.3. Всего в дереве $1 + 5 + 12 + 24 = 42$ узла классификации и 30 объектов. Высота дерева равна 5 уровням от корня до объекта. Это не меньше рекомендованного минимума в 25 узлов и высоту 5.

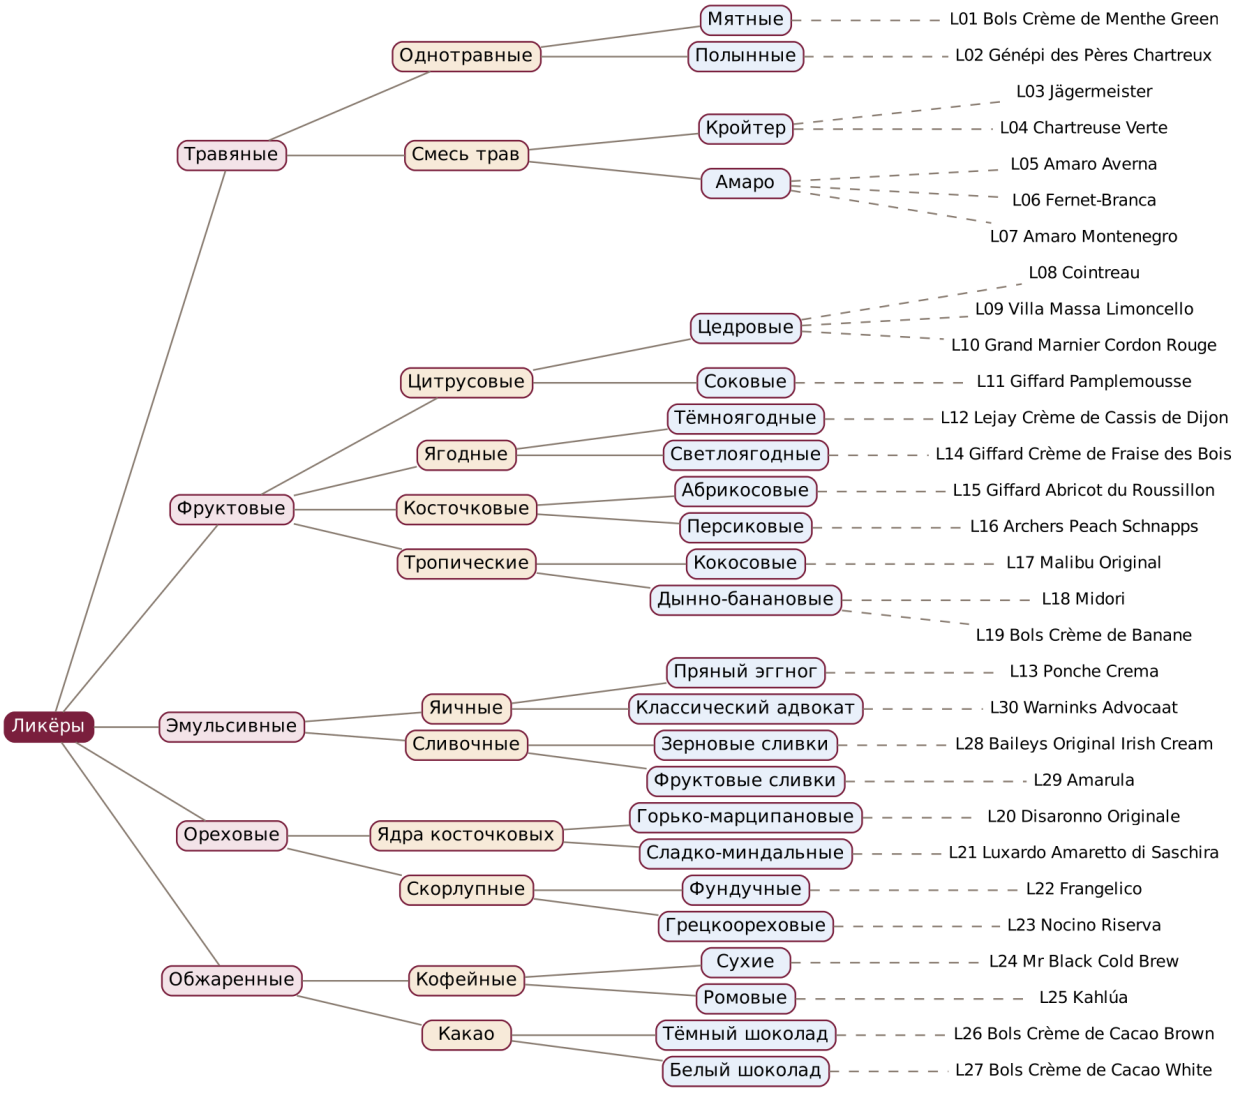


Рисунок 1.1 – Иерархия предметной области. Сплошные рёбра — таксономия вкуса, пунктир — объекты датасета

Почему основа деления — вкус. Рассматривались и другие вари-

анты основания дерева.

— По крепости или сладости с рубежами вроде «до 20 %» или «20–30 %». Вариант отвергнут. Крепость и сладость — числовые признаки объекта, а не смысловое деление. По методическим указаниям числовые признаки анализируются в мерах близости и фильтрах поиска, а не в дереве. Кроме того, граница искусственна. Ликёры с 19 и 21 % оказались бы в разных ветвях.

— По стране. Отвергнуто, потому что страна — плоский номинальный признак без внутренней структуры. Одна страна объединяет совершенно разные напитки. Италия — это и горький Fernet-Branca, и сладкий Limoncello.

— По базовому спирту — зерновому, виноградному или ромовому. Отвергнуто, так как для большинства ликёров база не определяет вкус и не известна покупателю.

Вкусовая основа — главный критерий выбора ликёра. Ветви дерева совпадают с тем, как покупатель формулирует желание вроде «хочу что-то травяное». Поэтому вкусовая иерархия выбрана основой классификации, а мера по этому дереву получила в ЛР2 наибольший вес.

Почему все листья на одной глубине. Все вкусовые листья находятся на уровне L3, даже если у группы L2 мало представителей. Одинаковая глубина делает расстояние по дереву сравнимым для любых пар. Мера У–Палмера применяется без поправок на неравномерную глубину, что описано в разделе 2.4. Деление на L2 выбрано по значимому признаку производства и вкуса. В травяной ветви это одна трава или сбор трав, во фруктовой — тип плода, в эмульсивной — яичная или сливочная основа.

1.3 Признаки объектов

Набор признаков и их типы приведены в таблице 1.1. По требованиям ЛР1 нужен хотя бы один бинарный, один количественный, один категориальный и один не приводимый к числовым признак. Датасет содержит их все.

Таблица 1.1 – Признаки объекта и их роль в системе

Признак	Тип	Значения	Использование
`abv_pct`	количественный	15–55 %	мера (евклидова), фильтр-диапазон
`sugar_gpl`	количественный	80–400 г/л	мера (евклидова), фильтр-диапазон
`volume_l`	количественный	0,5–1,0 л	мера (евклидова), фильтр-диапазон
`bitter`	бинарный	да / нет	мера SMC, фильтр «горечь»
`wood_contact`	бинарный	да / нет	мера SMC, фильтр «дерево»
`sugar_class`	категориальный порядковый, лингвистическая переменная	малосладкий, умеренный, сладкий, crème	порядковая мера, фильтр по термам
`taste` (L1/L2/L3)	иерархический, метка класса	24 листа дерева	мера У–Палмера, фильтр по узлам дерева
`country`	номинальный	12 стран	δ-функция, фильтр
`producer`	номинальный	24 производителя	δ-функция, фильтр, текстовый поиск
`name`, `notes`	не приводимые к числовым, текст	свободный текст	текстовый поиск и отображение, в меру не входят
`id`, `source_quality`	служебные	—	идентификация, происхождение данных

Обоснование отдельных признаков приведено ниже.

— **Крепость и сахар** — основные количественные характеристики вкуса ликёра. Значения сахара меняются от 80 г/л у сухого Fernet-Branca до 400 г/л у кремовых ликёров. Объём бутылки — слабый, но объективный признак. Литровые и полулитровые бутылки характерны для определённых стилей вроде сливочных и альпийских. В мере ЛР2 объём остаётся одной из трёх равноправных числовых осей.

— **Бинарные признаки** определены строго, чтобы их значение не зависело от вкуса эксперта. Признак `bitter` означает выраженную структурную горечь. Горечь ментола у мятного ликёра не считается. Признак `wood_contact` означает выдержку ликёра в бочке или выдержанный базовый спирт, как коньяк в Grand Marnier или виски в Baileys.

— **Класс сладости** — лингвистическая переменная над `sugar_gpl` с четырьмя термами. Малосладкий — менее 200 г/л, умеренный

— 200–250, сладкий — 250–350, crème — от 350 г/л. Порог 250 г/л взят из регламента ЕС. Начиная с него ликёр может называться «crème de...» [3]. Это категориальный признак, приводимый к числовой шкале, как и предусмотрено заданием. Он нужен, чтобы пользователь мог задавать сладость словами в фильтре ЛР4, а мера мягче различала соседние термы.

— **Текстовые признаки** — название и описание — к числам не приводятся. В меру близости они не входят. На 30 объектах нельзя надёжно оценить семантическую близость описаний, а word2vec-модели требуют большого корпуса. Название используется в текстовом поиске ЛР4.

1.4 Датасет

Датасет хранится в файле `1-dataset/dataset.json` и приведён в таблице 1.2. Копия для просмотра сохранена в `liqueurs_dataset_30.xlsx`. Формат JSON выбран потому, что признак `taste` — вложенная структура с уровнями L1, L2, L3 и кодом пути. JSON сохраняет её и типы значений без дополнительного разбора. Описание полей и правила построения лингвистической переменной хранятся в том же файле, поэтому датасет самодокументирован.

Таблица 1.2 – Датасет из 30 ликёров. Г — горечь, Д — контакт с деревом

ID	Название	Страна	Лист L3	%	г/л	л	Г	Д	Класс
L01	Bols Crème de Menthe Green	Нидерланды	Мятные	24	400	0,7	–	–	crème
L02	Génépi des Pères Chartreux	Франция	Полынные	40	200	0,5	+	–	умеренный
L03	Jägermeister	Германия	Кройтер	35	136	0,7	+	–	малосладкий
L04	Chartreuse Verte	Франция	Кройтер	55	250	0,7	+	–	сладкий
L05	Amaro Averna	Италия	Амаро	29	230	0,7	+	+	умеренный
L06	Fernet-Branca	Италия	Амаро	39	80	0,7	+	–	малосладкий
L07	Amaro Montenegro	Италия	Амаро	23	220	0,7	+	–	умеренный
L08	Cointreau	Франция	Цедровые	40	200	0,7	–	–	умеренный
L09	Villa Massa Limoncello	Италия	Цедровые	30	320	0,7	–	–	сладкий
L10	Grand Marnier Cordon Rouge	Франция	Цедровые	40	214	0,7	–	+	умеренный
L11	Giffard Pamplemousse	Франция	Соковые	16	260	0,7	–	–	сладкий
L12	Lejay Crème de Cassis de Dijon	Франция	Тёмноягодные	20	400	0,7	–	–	crème

Продолжение таблицы 1.2

ID	Название	Страна	Лист L3	%	г/л	л	Г	Д	Класс
L13	Ponche Crema	Венесуэла	Пряный эггног	15	240	0,75	–	–	умеренный
L14	Giffard Crème de Fraise des Bois	Франция	Светлоягодные	16	380	0,7	–	–	crème
L15	Giffard Abricot du Roussillon	Франция	Абрикосовые	25	280	0,7	–	–	сладкий
L16	Archers Peach Schnapps	Великобритания	Персиковые	18	280	0,7	–	–	сладкий
L17	Malibu Original	Барбадос	Кокосовые	21	180	0,7	–	–	малосладкий
L18	Midori	Япония	Дынно-банановые	20	300	0,7	–	–	сладкий
L19	Bols Crème de Banane	Нидерланды	Дынно-банановые	17	400	0,7	–	–	crème
L20	Disaronno Originale	Италия	Горько-марципановые	28	300	0,7	–	–	сладкий
L21	Luxardo Amaretto di Saschira	Италия	Сладко-миндальные	28	280	0,7	–	–	сладкий
L22	Frangelico	Италия	Фундучные	20	240	0,7	–	–	умеренный
L23	Nocino Riserva	Италия	Грецкоореховые	30	220	0,5	+	+	умеренный
L24	Mr Black Cold Brew	Австралия	Сухие	25	160	0,7	+	–	малосладкий
L25	Kahlúa	Мексика	Ромовые	16	393	0,7	–	–	crème
L26	Bols Crème de Cacao Brown	Нидерланды	Тёмный шоколад	24	395	0,7	–	–	crème
L27	Bols Crème de Cacao White	Нидерланды	Белый шоколад	24	395	0,7	–	–	crème
L28	Baileys Original Irish Cream	Ирландия	Зерновые сливки	17	224	1	–	+	умеренный
L29	Amarula	ЮАР	Фруктовые сливки	17	200	0,75	–	+	умеренный
L30	Warninks Advocaat	Нидерланды	Классический адвокат	17,2	260	0,7	–	–	сладкий

Выводы

Сформирован датасет из 30 ликёров с признаками пяти типов. Это количественные, бинарные, порядковые, номинальные и текстовые признаки. Построена иерархия предметной области по вкусовой основе. В ней 42 узла классификации и 30 объектов при высоте 5 уровней. Все вкусовые листья лежат на одной глубине. Числовые признаки оставлены атрибутами объектов, а не узлами дерева. Это определило схему ЛР2. Дерево сравнивается древесной мерой, а остальные признаки — своими частными мерами.

2 Меры близости (ЛР2)

2.1 Методика выбора мер

Все меры в работе приводятся к одной шкале близости. Значение $\mathrm{sim}(x, y)$ лежит в $[0, 1]$, причём $\mathrm{sim}(x, x) = 1$ и $\mathrm{sim}(x, y) = \mathrm{sim}(y, x)$. Если мерой является расстояние, оно нормируется в $[0, 1]$ и переводится в близость как $\mathrm{sim} = 1 - d$ [4]. Числовые признаки предварительно нормируются по каталогу методом min-max по формуле $x' = (x - \min)/(\max - \min)$. Без нормировки сахар с размахом 320 г/л подавил бы объём бутылки с размахом 0,5 л.

Признаки разнотипны, и единой меры для всего вектора нет. Для каждого типа выбирается своя частная мера, а затем строится обобщающая мера как их взвешенная сумма. Выбор между кандидатами одного типа проводится в три шага.

1. Для каждой меры строится матрица смежности $G_{ij} = g(o_i, o_j)$ размера 30×30 по всем парам объектов.

2. По матрице строится тепловая карта. На ней видно, выделяет ли мера блоки родственных объектов и насколько зернистая её шкала.

3. Карты и численные показатели сравниваются между собой. Это значения на эталонных парах заведомо похожих и заведомо различных ликёров, согласованность ранжирований пар по коэффициенту Спирмена ρ для 435 пар верхнего треугольника [5] и число уникальных значений. Чем уникальных значений меньше, тем больше пар неразличимы.

Расчёт выполняет скрипт `2-metrics/metrics.py`. Матрицы сохраняются в CSV, Excel и интерактивную HTML-страницу `out/matrices.html`, а тепловые карты — в PNG.

2.2 Числовые признаки

Кандидаты — семейство Минковского $d_p = \left(\frac{1}{D}\sum_k |x_k - y_k|^p\right)^{1/p}$ при $p = 1, 2, 3$ и ∞, то есть манхэттенская, евклидова, мера Минковского и мера Чебышёва. Пятым кандидатом выступает косинусное расстояние $d = 1 - \frac{x \cdot y}{\|x\|\,\|y\|}$. Множитель $1/D$ при трёх осях нормирует все меры в $[0, 1]$. Значения на эталонных парах приведены в таблице 2.1, а согласованность и зернистость — в таблице 2.2.

Таблица 2.1 – Числовые меры расстояния на эталонных парах

Пара	$p = 2$	$p = 1$	$p = 3$	$p = \infty$	cos	Смысл пары
L26–L27	0,000	0,000	0,000	0,000	0,000	какао-ликёры, числа совпадают
L08–L10	0,025	0,015	0,030	0,044	0,001	Cointreau / Grand Marnier
L20–L21	0,036	0,021	0,043	0,063	0,001	два амаретто
L15–L16	0,101	0,058	0,121	0,175	0,025	абрикос / персик
L06–L30	0,452	0,369	0,484	0,563	0,614	Fernet / Advocaat
L04–L13	0,581	0,377	0,694	1,000	0,452	крайние по крепости, 55 и 15 %

Таблица 2.2 – Согласованность ранжирований пар по Спирмену ρ и зернистость шкалы

Мера	ρ с $p = 2$	ρ с $p = \infty$	ρ с cos	Уникальных из 435	Пар в связках
евклидова ($p = 2$)	—	0,970	0,881	354	148
манхэттенская ($p = 1$)	0,974	0,903	0,906	227	310
Минковского ($p = 3$)	0,995	0,987	0,857	359	141
Чебышёва ($p = \infty$)	0,970	—	0,809	92	406
косинусная	0,881	0,809	—	406	57

На эталонных парах порядок «близко — далеко» у всех мер правильный, поэтому решают свойства шкалы.

— **Чебышёв отвергнут.** Мера видит только координату с наибольшей разностью. В результате 93 % пар попадают в связки, всего 92 уникальных значения на 435 пар. У Baileys и Amarula совпадают крепость и почти совпадает сахар. Однако расстояние 0,5 целиком определяется объёмом бутылки, 1,0 л против 0,75 л. Для пары L04–L13 расстояние 1,0 задано только крепостью, а сахар не учитывается вовсе.

— **Минковский $p = 3$ отвергнут** как промежуточный шаг к Чебышёву. Его ранжирование почти совпадает с чебышёвским, $\rho = 0{,}987$, а нового смысла по сравнению с $p = 2$ он не даёт.

— **Косинусная мера отвергнута.** Она сравнивает направление вектора, а не величину. Пропорциональные, но разные векторы получают расстояние 0. Например, ликёр вдвое крепче и вдвое слаще оказался бы «тем же самым». Это нарушает аксиому $d(x, y) = 0 \Leftrightarrow x = y$. На близких парах мера слишком оптимистична и даёт 0,001 для L08–L10, а с остальными мерами она согласуется хуже всех.

— **Евклидова мера выбрана** вместо манхэттенской. Ранжирования почти совпадают, $\rho = 0{,}974$. Однако у евклидовой меры вклад разности квадратичный. Одно крупное отличие вроде 20 п. п. крепости штрафуется сильнее, чем та же сумма, распределённая по осям. Для ликёров это верно, потому что большая разница в крепости важнее нескольких мелких отличий. Кроме того, евклидова мера — единственная изотропная L_p-норма, а её шкала зернистее, 354 уникальных значения против 227.

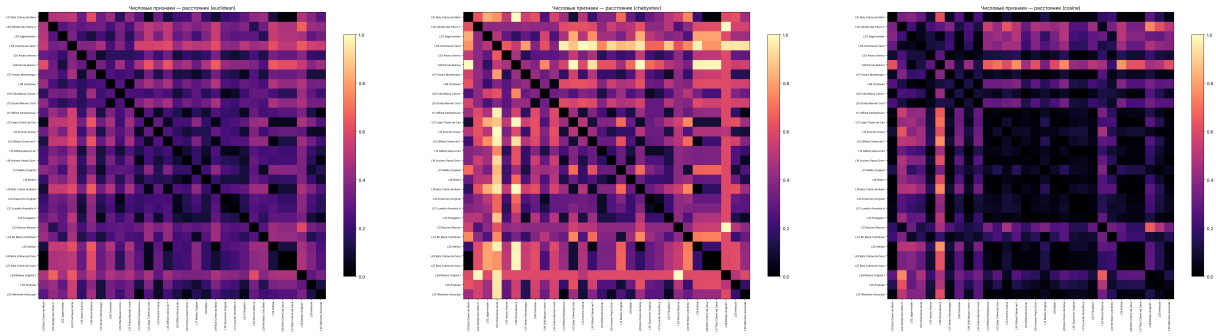


Рисунок 2.1 – Тепловые карты числовых расстояний. Слева евклидово, в центре Чебышёва, справа косинусное

На рисунке 2.1 видно, что карта Чебышёва ступенчатая. Косинусная карта почти однородно тёмная, потому что почти все пары для неё близки. Итоговая частная мера имеет вид $\mathrm{sim}_{num} = 1 - \sqrt{\frac{1}{3}\sum_k (x'_k - y'_k)^2}$.

2.3 Бинарные признаки

Для вектора (`bitter`, `wood_contact`) рассмотрены ассоциативные меры на таблице сопряжённости [6]. Здесь a — число совпадающих единиц, b и c — рассогласования, d — число совпадающих нулей и $n = a + b + c + d = 2$. Меры записываются как Жаккар $a/(a+b+c)$, Дайс $2a/(2a+b+c)$, Сокал–Миченер (SMC) $(a+d)/n$ и Роджерс–Танимото $(a+d)/(a+d+2(b+c))$.

Таблица 2.3 – Бинарные меры близости на тестовых парах

Пара	Векторы	Жаккар	Дайс	SMC	Роджерс–Танимото
L26–L27	(0,0)·(0,0)	$0/0 \Rightarrow 1^*$	$0/0 \Rightarrow 1^*$	1,000	1,000
L28–L30	(0,1)·(0,0)	0,000	0,000	0,500	0,333
L05–L01	(1,1)·(0,0)	0,000	0,000	0,000	0,000

У 19 из 30 ликёров вектор равен $(0, 0)$. Это десертный стиль без горечи и выдержки, и для таких данных совпадение нулей содержательно. **Жаккар и Дайс отвергнуты**, потому что они игнорируют d и на паре $(0, 0) \cdot (0, 0)$ дают неопределённость $0/0$, что видно из таблицы 2.3. Baileys и Advocaat получили бы у них близость 0, хотя различаются одним признаком. **Роджерс–Танимото отвергнута.** При двух признаках двойной штраф сжимает шкалу, и одно различие даёт близость $1/3$. **Выбран SMC**, доля совпавших признаков. Мера линейна и интерпретируема, у неё нет неопределённостей и выполнены все требования к близости. Если позже появятся длинные разреженные бинарные векторы вроде тегов-ингредиентов, выбор стоит пересмотреть в пользу Жаккара.

2.4 Мера по таксономии вкуса

Признак `taste` — лист дерева из ЛР1. δ-функция «совпал лист или нет» потеряла бы структуру. Пары «амаро–кройтер» и «амаро–банан» обе получили бы 0. Поэтому нужна графовая мера на дереве. Рассмотрены три класса таких мер.

— **Рёберные меры.** Это кратчайший путь $d = \mathrm{depth}(x) + \mathrm{depth}(y) - 2\,\mathrm{depth}(\mathrm{LCA})$ [7], мера Ликока–Чодороу на логарифме нормиро-

ванного пути и мера У–Палмера $\mathrm{sim} = 2\,\mathrm{depth}(\mathrm{LCA})/(\mathrm{depth}(x) + \mathrm{depth}(y))$ [8].

— **Узловые меры** по информативности узла $IC(c) = -\log p(c)$. Это меры Резника [9], Лина [10] и Цзяна–Конрата. Им нужны частоты понятий в корпусе. Оценивать частоты по 30 объектам ненадёжно, поэтому узловые меры отвергнуты.

— **Гибридные меры** Ли и др. Это нелинейная комбинация пути и глубины с двумя подгоночными параметрами. Для трёхуровневого дерева она избыточна.

Выбрана мера У–Палмера. В отличие от числа рёбер она учитывает глубину общего предка. Родство на уровне L2 конкретнее родства на уровне L1. Мера самонормирована в $[0, 1]$ и даёт $\mathrm{sim}(x, x) = 1$. Ей не нужны корпусные частоты, и она не меняет вид при добавлении уровня L4. Все листья лежат на глубине 3, поэтому мера принимает четыре значения из таблицы 2.4. Она эквивалентна взвешенному общему пути с равными весами рёбер, а неравные веса уровней задаются параметрически.

Таблица 2.4 – Значения меры У–Палмера

Общий предок	depth(LCA)	sim	Пример
тот же лист L3	3	1,000	L05–L07, оба «Амаро»
общий L2, разные L3	2	0,667	L26–L27, тёмный и белый шоколад
общий L1, разные L2	1	0,333	L01–L03, однотравный и сбор трав
только корень	0	0,000	L08–L26, фруктовые и обжаренные

2.5 Порядковый и номинальные признаки

Для лингвистической переменной `sugar_class` из четырёх термов используется порядковая мера $\mathrm{sim} = 1 - |\mathrm{ord}(x) - \mathrm{ord}(y)|/3$. Соседние термы различаются на $1/3$, а противоположные — на 1. Номинальные признаки `country` и `producer` сравниваются δ-функцией. Отношения порядка или иерархии между странами нет, а географическая близость не означает вкусовой. Италия и Франция производят ликёры всех ветвей дерева.

2.6 Обобщающая мера

Все частные меры имеют одну шкалу $[0, 1]$. Поэтому их выпуклая комбинация

$$\mathrm{sim}(x, y) = \sum_k \omega_k \, \mathrm{sim}_k(x, y), \qquad \sum_k \omega_k = 1, \ \omega_k \geq 0, \tag{2.1}$$

сама является близостью в $[0, 1]$ и даёт $\mathrm{sim}(x, x) = 1$. Она учитывает все признаки, кроме служебных и текстовых. Экспертные веса и их обоснование приведены в таблице 2.5.

Таблица 2.5 – Экспертные веса частных мер

Частная мера	Признаки	ω	Обоснование
У–Палмер	taste	0,35	вкус — главный смысл рекомендации ликёра
евклидова	abv, sugar, volume	0,30	крепость и сладость — второй по важности фактор выбора
SMC	bitter, wood	0,15	заметные, но грубые модификаторы вкуса
порядковая	sugar_class	0,10	производный признак, вес занижен, чтобы не считать сладость дважды
δ-функция	country	0,05	слабый маркер стиля
δ-функция	producer	0,05	маркер линейки вроде серии Bols crème

Экспертные веса нужно проверить на устойчивость. Для этого рассчитаны пять схем весов, не использующих экспертное знание. Это равные веса $1/6$, веса пропорционально числу признаков в блоке, веса по энтропии Шеннона распределения значений меры [11], веса по среднеквадратическому отклонению и метод CRITIC по произведению контрастности и конфликта [12]. Полученные веса показаны на рисунке 2.2, а сравнение итоговых матриц — в таблице 2.6 и на рисунке 2.3.

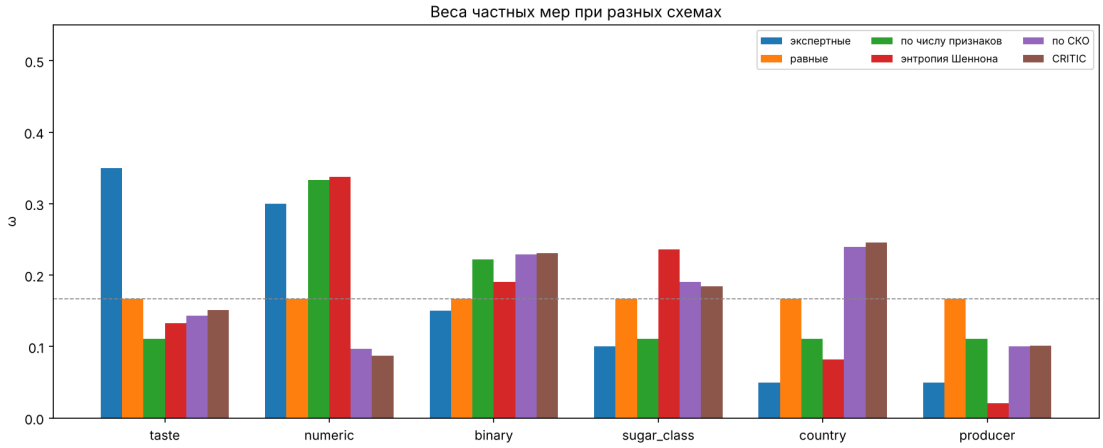


Рисунок 2.2 – Веса частных мер при разных схемах

Таблица 2.6 – Отличие итоговых мер от экспертной. Всего 435 пар

Схема весов	Спирмен ρ	средн. $\lvert\Delta\rvert$	макс. $\lvert\Delta\rvert$	Объектов с другим ближайшим соседом
по числу признаков	0,951	0,075	0,239	6 из 30
энтропия Шеннона	0,937	0,125	0,244	9 из 30
равные	0,925	0,061	0,232	7 из 30
по СКО	0,883	0,067	0,261	8 из 30
CRITIC	0,883	0,073	0,264	8 из 30

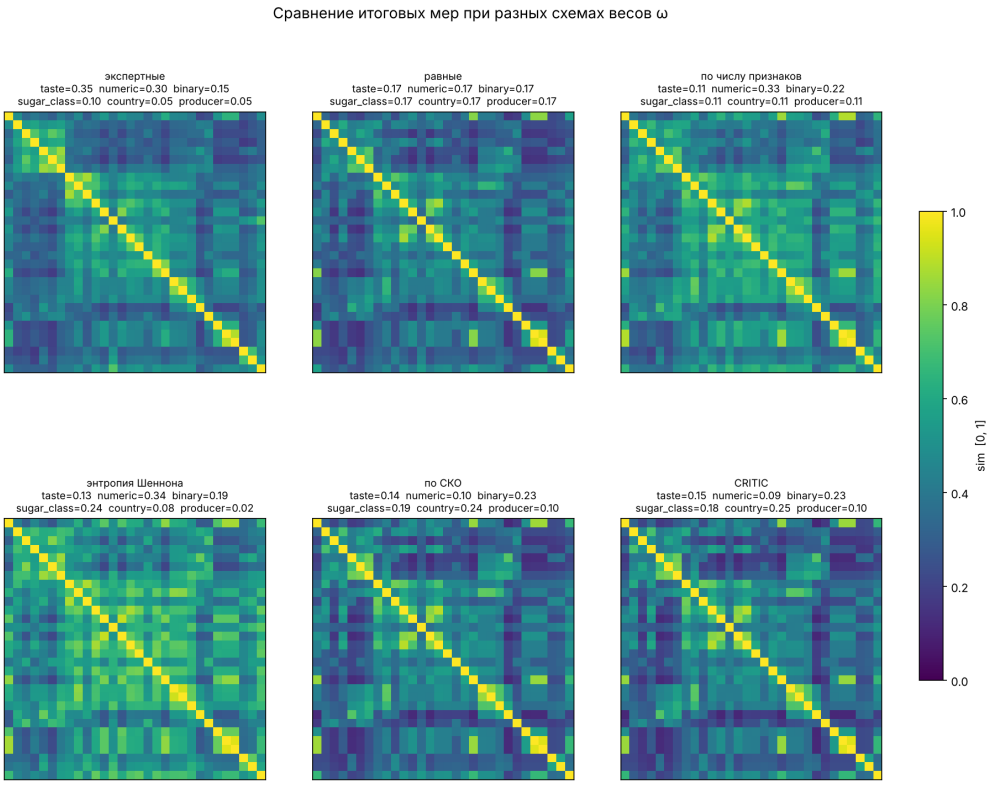


Рисунок 2.3 – Итоговые матрицы близости при шести схемах весов на общей шкале

Канонические «двойники» не распадаются ни в одной схеме. Это два какао-ликёра, два амаро, Cointreau и Grand Marnier, Baileys и Amarula. Они близки сразу по нескольким частным мерам. Меняется только второй ряд соседей. CKO и CRITIC дают стране вес около 0,24 вместо 0,05, потому что δ-функция статистически контрастна. В ней много нулей и редкие единицы. В результате Limoncello отходит от Cointreau к Disaronno по общей стране Италии, хотя с Cointreau у него общий лист «цедровые». Энтропия, наоборот, почти обнуляет производителя и завышает класс сладости. Последний коррелирует с числовым блоком, $r = 0{,}54$. Вывод прост. Объективные схемы измеряют контрастность шкалы, а не смысл рекомендации. Экспертные веса оставлены основными, а альтернативные схемы использованы как проверка устойчивости.

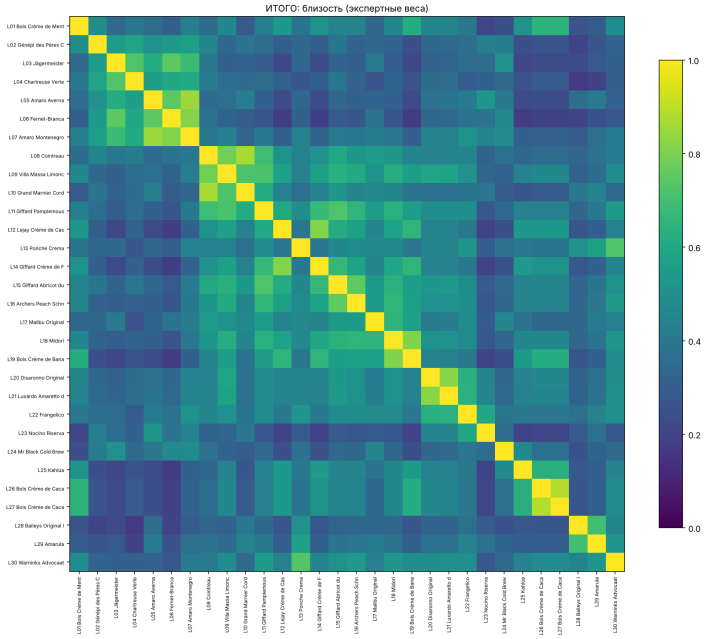


Рисунок 2.4 – Итоговая матрица близости с экспертными весами

На итоговой карте на рисунке 2.4 видны блоки ветвей таксономии. Это травяные L01–L07, цедровые L08–L11, какао L26–L27 и сливочные L28–L29. Ближайшие соседи по итоговой мере экспертно верны и показаны в таблице 2.7. Максимум вне диагонали равен 0,883, поэтому разные объекты не слипаются в 1.

Таблица 2.7 – Ближайшие соседи по итоговой мере

Ликёр	Три ближайших соседа и близость
L26 Crème de Cacao Brown	L27 Cacao White (0,883), L01 Crème de Menthe (0,647), L25 Kahlúa (0,632)
L05 Amaro Averna	L07 Montenegro (0,848), L06 Fernet-Branca (0,750), L03 Jägermeister (0,618)
L08 Cointreau	L10 Grand Marnier (0,867), L09 Limoncello (0,789), L11 Pamplemousse (0,691)
L28 Baileys	L29 Amarula (0,696), L13 Ponche Crema (0,504), L30 Advocaat (0,453)
L24 Mr Black	L03 Jägermeister (0,505), L07 Montenegro (0,483), L25 Kahlúa (0,476)

Выводы

Для каждого типа признаков выбрана частная мера по формальной методике. Она включает матрицы смежности, тепловые карты, эталонные пары, согласованность ранжирований и зернистость шкалы. Выбраны нормированная евклидова мера для числовых признаков, SMC для бинарных, мера У–Палмера для таксономии вкуса, порядковая мера для класса сладости и δ-функция для номинальных признаков. Обобщающая мера — взвешенная сумма с экспертными весами. Её устойчивость подтверждена сравнением с пятью объективными схемами весов. Эта мера — основа всех рекомендаций ЛР3 и функции полезности ЛР4.

3 Рекомендательная система (ЛР3)

3.1 Постановка задачи и выбор подхода

Рекомендательная система по профилю предпочтений пользователя строит ранжированный список объектов каталога. Разработаны три версии.

— **PCv1 (v1)**. На вход подаётся один объект-затравка, на выходе получается список, ранжированный по убыванию близости к затравке.

— **PCv2 (v2)**. На вход подаётся набор лайков, на выходе получается ранжированный список.

— **PCv3 (v3)**. На вход подаются лайки и дизлайки, на выходе получается ранжированный список.

Выбран **контентный** подход. В нём релевантность объекта определяется сходством его признаков с объектами, которые понравились пользователю [1, 2]. Коллаборативная фильтрация отвергнута. Она требует матрицы оценок многих пользователей, а в учебной системе таких данных нет. Контентный подход обладает свойствами, важными для этой задачи.

— **Нет проблемы холодного старта для объектов.** Новый ликёр рекомендуется сразу после добавления в каталог, так как оценки других пользователей ему не нужны [13]. Новому пользователю достаточно одного лайка. Это ровно режим v1.

— **Не возникает проблемы «белой вороны».** Пользователю с редким вкусом не нужны похожие на него пользователи. Рекомендации строятся только по его собственному профилю.

— **Проблема устаревших предпочтений решается** учётом времени лайков в подходе Б и возможностью начать профиль заново.

Ограничение подхода — узкая специализация. Система рекомендует только похожее на уже оценённое. Его частично компенсирует учёт нескольких групп интересов из раздела 3.3.

Как формируется ранжированный список. Каждому кандидату x, то есть объекту каталога без оценки пользователя, сопоставляется числовая оценка релевантности $r(x)$. Список — это кандидаты по убыванию $r(x)$. При равенстве они упорядочены по идентификатору, чтобы порядок был детерминированным. Пользователю показываются первые N элементов. Все версии используют одну и ту же обобщающую меру близости из ЛР2 (2.1). Они различаются только способом вычисления $r(x)$. Попарные близости предвычисляются в матрицу 30×30. При таком размере каталога пересчёт не нужен, а доступ занимает $O(1)$.

3.2 PCv1: рекомендации по затравке

Для затравки s релевантность равна близости к ней, то есть $r(x) = \mathrm{sim}(s, x)$. Затравка из выдачи исключается. Пример выдачи для двух затравок приведён в таблице 3.1. В обоих случаях первые позиции занимают объекты того же листа или той же группы L2 таксономии.

Таблица 3.1 – Выдача PCv1, top-5

Затравка	Выдача и релевантность
L26 Crème de Cacao Brown	L27 Cacao White (0,883), L01 Crème de Menthe (0,647), L25 Kahlúa (0,632), L19 Crème de Banane (0,620), L12 Crème de Cassis (0,532)
L05 Amaro Averna	L07 Montenegro (0,848), L06 Fernet-Branca (0,750), L03 Jägermeister (0,618), L04 Chartreuse Verte (0,562), L23 Nocino (0,530)

3.3 PCv2: набор лайков

3.3.1 Рассмотренные подходы

Пусть $L = (l_1, \ldots, l_m)$ — лайки в порядке их установки, а $s_i(x) = \mathrm{sim}(x, l_i)$. Реализованы и сравнены шесть способов получить из нескольких лайков одну оценку или один список.

A. Среднее арифметическое считает $r(x) = \frac{1}{m} \sum_i s_i(x)$. Подход прост, но зависит от домена. Если лайки близки друг к другу, среднее работает как близость к центру интереса. Если пользователю нравятся два

далёких объекта, среднее поднимает объекты посередине, не похожие ни на один из лайков. Например, при лайках Amaro Averna и Baileys в первую пятёрку попадает Ponche Crema. Шестым идёт Grand Marnier, близость которого к обоим лайкам около 0,4.

Б. Учёт времени лайков — взвешенное среднее с весами $w_i = \gamma^{m-i}$, где $\gamma = 0{,}7$. Последний лайк весит 1, предыдущий 0,7 и так далее. Подход отражает смещение вкуса со временем и решает проблему устаревших предпочтений. Однако он наследует от А эффект «середины».

В. Взвешенное суммирование задаёт веса не временем, а структурой профиля. Вес равен $w_i = 1/|G(l_i)|$, где $G(l_i)$ — группа интересов лайка из подхода Г. Каждая группа интересов вносит одинаковый вклад, даже если в ней пять лайков, а в другой один.

Максимум считает $r(x) = \max_i s_i(x)$ как близость к ближайшему лайку. Эффекта «середины» нет, но одна группа интересов может занять всю выдачу.

Г′. Сшивание списков по каждому лайку строит для каждого лайка свой список по убыванию $s_i(x)$. Затем списки сшиваются по одному объекту от каждого по очереди, а дубликаты устраняются.

Г. Выделение групп лайков разбивает лайки на группы интересов. Две группы объединяются, если между какими-то их лайками близость не ниже порога θ. Это компоненты связности графа лайков по одиночной связи. Внутри группы g оценка равна среднему $r_g(x) = \frac{1}{|g|} \sum_{l \in g} \mathrm{sim}(x, l)$. Внутри связной группы эффекта «середины» нет, потому что середина между похожими объектами сама похожа на них. Итоговая выдача сшивается из списков групп по одному объекту от каждой группы без дубликатов. Группы упорядочены по размеру, и первой идёт группа с наибольшим числом лайков.

3.3.2 Сравнение качества подходов

Чтобы выбрать подход, нужна проверка, а не только рассуждение. Вкус пользователя смоделирован группами L2 таксономии [14]. Пользователь с k интересами лайкает все объекты k групп L2, кроме последнего в каждой группе. Отложенные объекты нужно вернуть в top-5. Перебраны

все сочетания групп. Получилось 12 сценариев при $k = 1$, 66 при $k = 2$ и 220 при $k = 3$. Использованы три метрики.

— **recall(5)** — доля отложенных объектов в первых пяти позициях.

— **coverage(5)** — доля групп интересов, которым служит хотя бы один элемент выдачи. Ближайший к элементу лайк лежит в этой группе. Метрика отражает разнообразие выдачи по интересам [15].

— **support(5)** — средняя близость элемента выдачи к ближайшему лайку. Малое значение означает рекомендации, не похожие ни на что.

Таблица 3.2 – Сравнение подходов PCv2 при $N = 5$. R — recall(5), C — coverage(5), S — support(5)

	2 группы интересов (66)			3 группы интересов (220)		
Подход	R	C	S	R	C	S
А. среднее	0,750	0,894	0,650	0,649	0,742	0,677
Б. время	0,826	0,932	0,654	0,733	0,808	0,681
В. баланс групп	0,818	0,955	0,659	0,747	0,836	0,691
максимум	0,826	0,932	0,670	0,782	0,886	0,707
Г′. по каждому лайку	0,818	1,000	0,657	0,796	0,983	0,690
Г. группы лайков	0,811	**1,000**	0,658	**0,797**	**1,000**	0,693

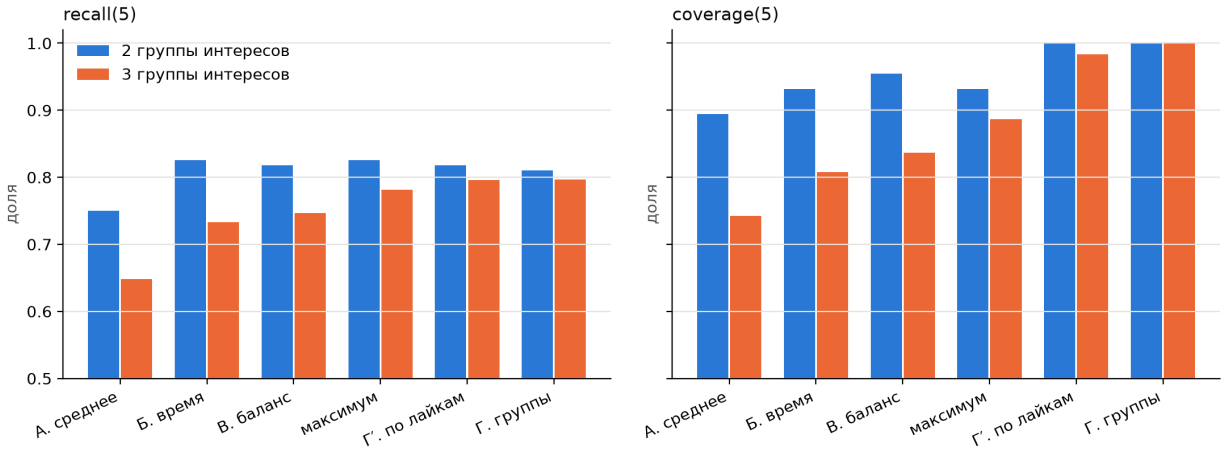


Рисунок 3.1 – Метрики recall(5) и coverage(5) подходов PCv2 для двух и трёх групп интересов

При одной группе интересов все подходы равны и дают recall 0,917 и coverage 1. Различия появляются при нескольких интересах, что видно из таблицы 3.2 и рисунка 3.1. Среднее А оказалось хуже всех. При трёх

интересах теряется треть отложенных объектов, а каждая четвёртая группа не представлена в выдаче. Учёт времени Б и баланс групп В улучшают среднее, но сохраняют его главный недостаток. Максимум даёт наибольший support. Каждый элемент его выдачи действительно близок к какому-то лайку, но не все интересы попадают в выдачу, coverage равен 0,886. Сшивание по лайкам Г′ и по группам Г обслуживают все интересы. При этом Г не даёт интересу с большим числом лайков занять несколько очередей сшивания. Три амаро и Baileys дают две группы, а не четыре списка. При двух интересах подходы Б, максимум, Г′ и Г различаются не более чем на один отложенный объект из 132. При трёх лучшим по recall и coverage оказывается Г.

Выбор порога θ. Порог должен объединять лайки одного интереса и не склеивать разные. На рисунке 3.2 показано распределение итоговой близости пар по положению в таксономии. Пары из разных ветвей L1 не превышают 0,647, а медиана пар с общим L2 равна 0,667. Порог $\theta = 0{,}65$ лежит на этой границе. Перебор порога на рисунке 3.3 подтверждает выбор. При $\theta = 0{,}65$ достигается максимум recall(5) для трёх интересов, 0,797, и полное покрытие интересов. При меньших порогах разные интересы склеиваются, и coverage падает до 0,83.

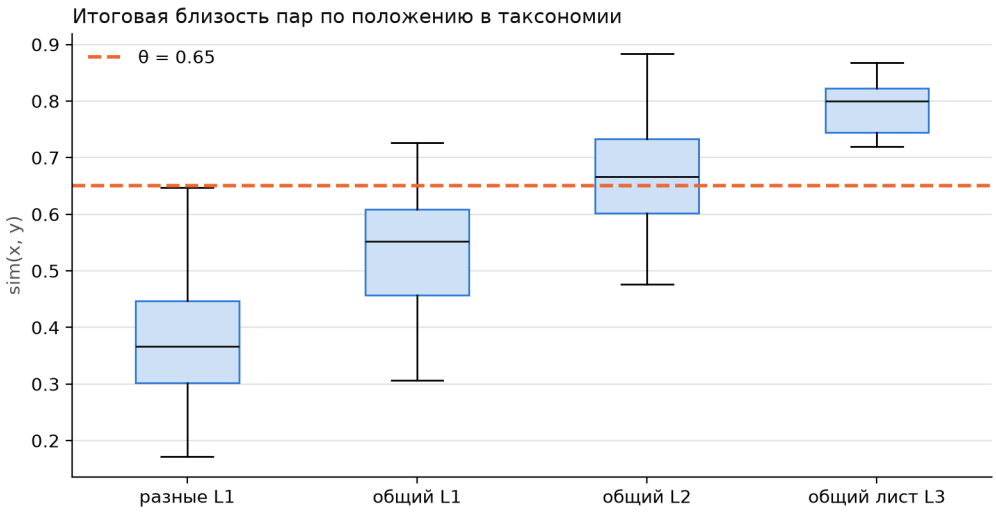


Рисунок 3.2 – Итоговая близость пар в зависимости от глубины общего предка в таксономии

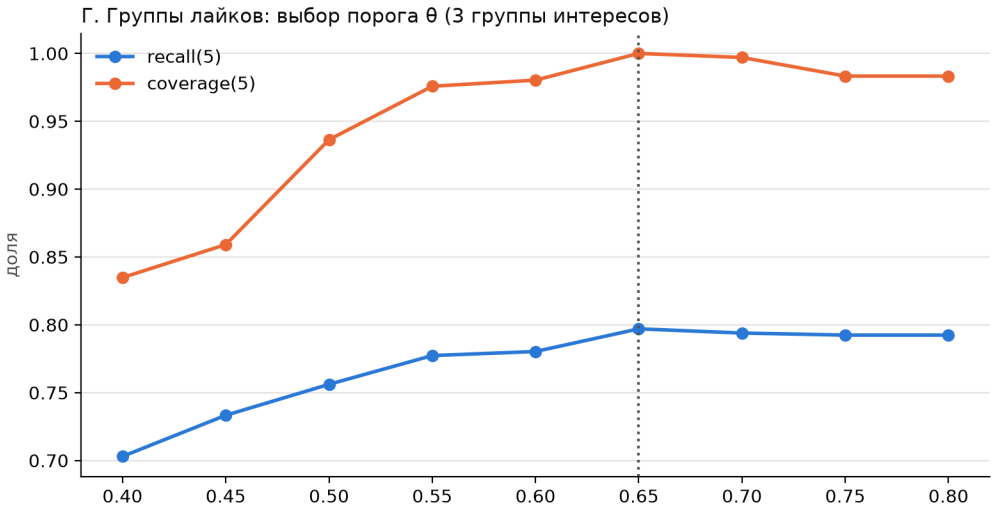


Рисунок 3.3 – Подбор порога группировки θ. Три группы интересов, 220 сценариев

Пример выдачи для лайков «Amaro Averna, Baileys» в таблице 3.3 иллюстрирует разницу. Среднее занижает оценки и поднимает объекты между интересами. Максимум отдаёт четыре места из пяти амаро. Подход Г чередует интересы.

Таблица 3.3 – Выдача PCv2 для лайков L05 Amaro Averna и L28 Baileys

Подход	top-5 и оценка
А. среднее	L07 (0,571), L29 (0,557), L06 (0,478), L03 (0,423), L13 (0,420)
Б. время	L29 (0,581), L07 (0,522), L13 (0,435), L06 (0,430), L10 Grand Marnier (0,414)
максимум	L07 (0,848), L06 (0,750), L29 (0,696), L03 (0,618), L04 (0,562)
Г. группы лайков	L07 (0,848), L29 (0,696), L06 (0,750), L13 (0,504), L03 (0,618)

Итог PCv2. По умолчанию используется подход Г с порогом $\theta = 0{,}65$. Остальные подходы доступны в интерфейсе для сравнения. Выбор подтверждён проверкой на датасете. Он согласуется с идеей выделения групп лайков, где одну группу можно усреднять, а разные группы нужно показывать по очереди.

3.4 PCv3: лайки и дизлайки

3.4.1 Рассмотренные подходы

Дизлайк несёт информацию, противоположную лайку. Однако использовать её симметрично нельзя. Типичная ситуация взята из примера с музыкой. Пользователю нравится весь жанр и почти весь материал исполнителя, кроме одной композиции. Если штрафовать всё, что похоже на эту композицию, система испортит весь любимый жанр. Дизлайк должен сужать интерес, а не отменять его. Анкетирование о причинах неприязни отвергнуто. Длинная анкета раздражает пользователя, и он может уйти. Причину неприязни система должна вывести из соотношения лайков и дизлайков. Реализованы четыре политики учёта дизлайков D. Через $\mathrm{dis}(x) = \max_{d \in D} \mathrm{sim}(x, d)$ обозначена близость к ближайшему дизлайку, а через $\mathrm{sup}(x) = \max_{l \in L} \mathrm{sim}(x, l)$ — к ближайшему лайку.

1. **Только исключить дизлайки.** Из выдачи убираются сами дизлайкнутые объекты, остальное не меняется.

2. **Исключить похожие.** Объект x убирается, если $\mathrm{dis}(x) \geq \tau$, где $\tau = 0{,}7$.

3. **Вычитание** по аналогии с формулой Роккио [16, 17], то есть $r'(x) = r(x) - \beta\,\mathrm{dis}(x)$.

4. **Контрастный штраф** $r'(x) = r(x) - \beta \max\bigl(0,\ \mathrm{dis}(x) - \mathrm{sup}(x)\bigr)$. Штрафуется только то, что ближе к дизлайку, чем к любому лайку. Объекты любимого жанра близки и к дизлайку, и к лайкам того же жанра. Поэтому они почти не штрафуются, а объекты, похожие именно на нелюбимый образец, опускаются.

Если у пользователя есть только дизлайки, оценка равна $r(x) = 1 - \mathrm{dis}(x)$. Рекомендуется то, что дальше всего от нелюбимого.

3.4.2 Сравнение качества политик

Два протокола моделируют два требования.

— **Дизлайк внутри любимого жанра**, 38 сценариев. В группе L2 из трёх и более объектов один объект дизлайкнут, один отложен, остальные лайкнуты. Хорошая политика сохраняет жанр, и recall отложенного объекта остаётся высоким.

— **Дизлайк чужого жанра**, 132 сценария. Лайки из группы A, дизлайк — один объект группы B. Хорошая политика не рекомендует остальные объекты группы B. Мера leakage(5), доля таких объектов в выдаче, должна быть низкой, а recall отложенного объекта из A — высоким.

Таблица 3.4 – Сравнение политик учёта дизлайков. Стратегия лайков Г, $N = 5$

Политика и параметр	recall, свой жанр	recall, чужой жанр	leakage, чужой жанр
1. только исключить	0,974	0,917	0,049
2. исключить похожие, $\tau = 0{,}7$	0,447	0,924	0,029
2. исключить похожие, $\tau = 0{,}8$	0,763	0,932	0,039
3. вычитание, $\beta = 1$	0,368	0,902	0,002
3. вычитание, $\beta = 0{,}25$	0,921	0,939	0,023
4. контрастный, $\beta = 0{,}5$	0,947	0,932	0,026
4. контрастный, $\beta = 1$	**0,921**	**0,932**	**0,017**
4. контрастный, $\beta = 2$	0,842	0,917	0,012

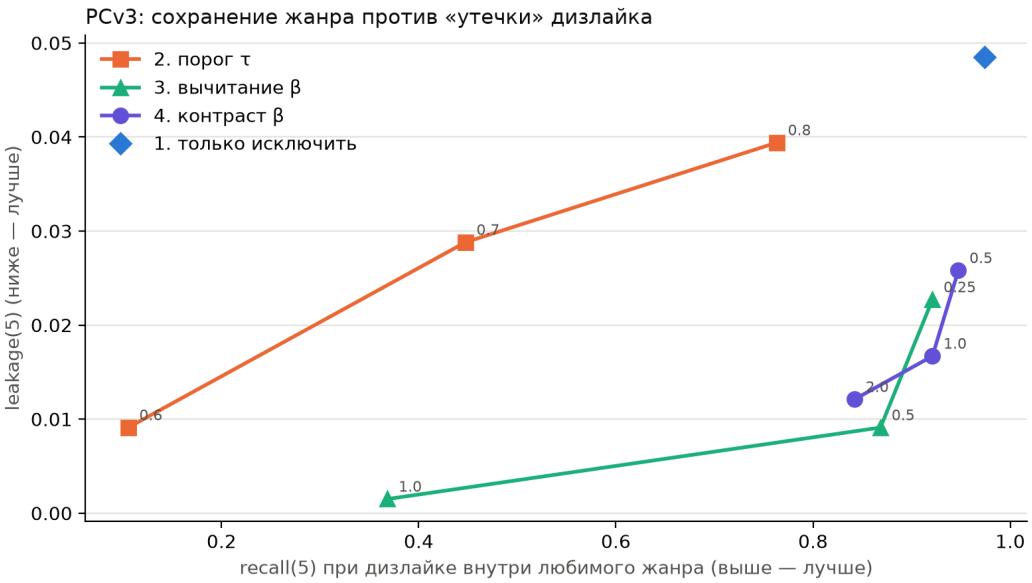


Рисунок 3.4 – Компромисс «сохранение жанра и утечка дизлайка». Подписи точек — значения τ или β

Результаты приведены в таблице 3.4 и на рисунке 3.4.

— политика 1 лучше всех сохраняет жанр, но почти не реагирует на дизлайк. Утечка у неё самая большая, 0,049.

— исключение по порогу и вычитание с полной силой $\beta = 1$ портят жанр. Recall в своём жанре падает до 0,37–0,45. Так проявляется проблема из примера с музыкой.

— вычитание с малым $\beta = 0{,}25$ сохраняет жанр, но примерно в 1,4 раза хуже по утечке, чем контрастный штраф с $\beta = 1$.

— **контрастный штраф с** $\beta = 1$ — лучший компромисс. Утечка втрое ниже, чем у политики 1, при почти той же сохранности жанра 0,921 и лучшем recall в чужом жанре 0,932.

Таблица 3.5 показывает это на примерах. В первом пользователь любит травяные ликёры Jägermeister, Averna и Montenegro, но не любит Fernet-Branca. Вычитание выдаёт сливочные ликёры с оценками около 0,1, то есть жанр потерян. Контрастный штраф оставляет Chartreuse и Génépi. Во втором примере Baileys нравится, а яичный Advocaat нет. Контрастный штраф опускает яичный Ponche Crema со второго места на пятое со штрафом 0,223. Причина в том, что он ближе к Advocaat, 0,727, чем к Baileys, 0,504.

Таблица 3.5 – Выдача PCv3 при разных политиках учёта дизлайков

Политика	лайки L03, L05, L07 и дизлайк L06	лайк L28 и дизлайк L30
1. исключить	L04, L02, L24, L23, L22	L29, L13, L10, L22, L05
2. порог τ	L04, L02, L24, L23, L22	L29, L10, L22, L05, L11
3. вычитание	L29, L28, L14, L25, L18, оценки 0,07–0,11	L29, L10, L05, L23, L06
4. контрастный	L04, L02, L24, L23, L22	L29, L10, L05, L23, L13

Итог PCv3. Используется контрастный штраф с $\beta = 1$. Он формализует интуицию «дизлайк уточняет, а не отменяет интерес» и подтверждён проверкой на датасете.

3.5 Объяснение рекомендаций

Пользователь должен понимать, почему ему рекомендован объект. Для каждого элемента выдачи система сохраняет ближайший лайк вроде «похож на Baileys», номер группы интересов и вклад каждой частной меры $\omega_k \operatorname{sim}_k$ в близость к этому лайку. Если сработал штраф, показываются его размер и дизлайк, на который похож объект. Объяснение стоит дёшево. Обобщающая мера (2.1) аддитивна, и её слагаемые уже вычислены.

3.6 Пользовательский интерфейс

На рисунке 3.5 показан режим PCv1. Слева каталог с карточками ликёров, справа профиль и выдача с оценкой и объяснением.

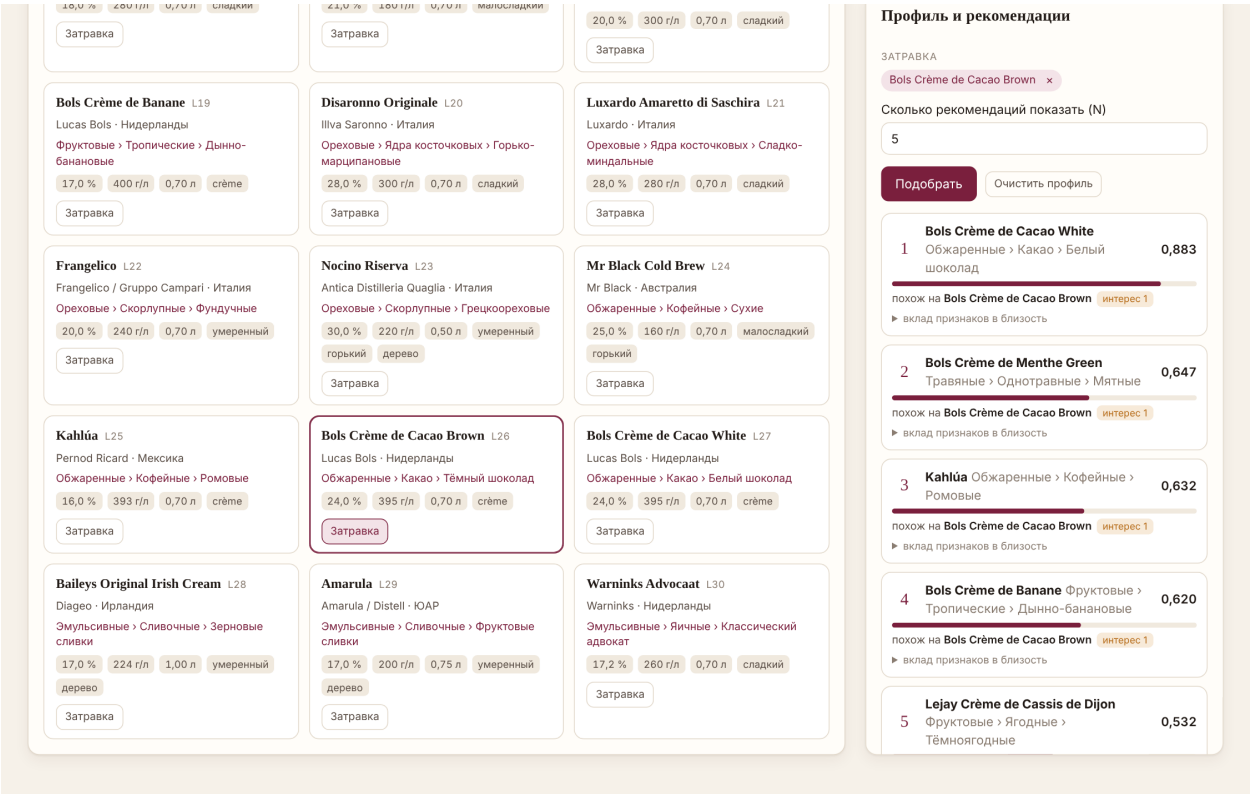


Рисунок 3.5 – PCv1. Затравка Crème de Cacao Brown

На рисунке 3.6 показаны режимы PCv2 и PCv3. В первом пользователь ставит несколько лайков, и выдача чередует группы интересов. Во втором добавляются дизлайки, и у наказанных объектов видны штраф и его причина.

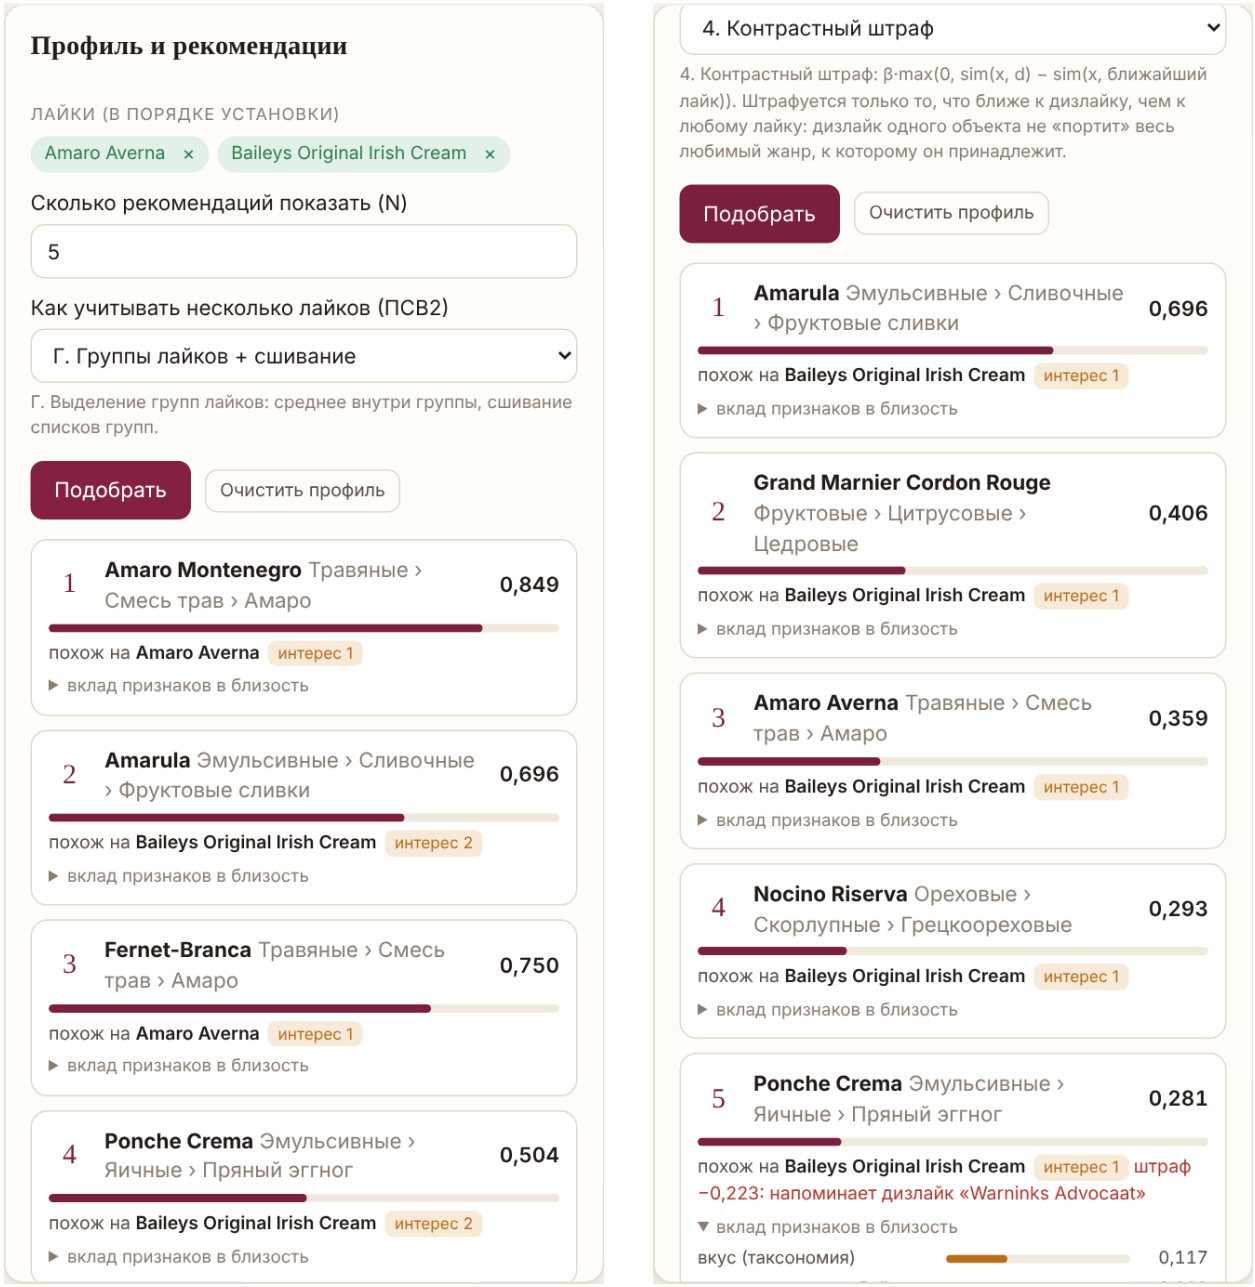


Рисунок 3.6 – PCv2. Лайки Averna и Baileys с чередованием групп интересов слева. PCv3. Лайк Baileys и дизлайк Advocaat, штраф Ponche Crema с вкладом признаков справа

Ввод проверяется на сервере, и все ошибки возвращаются одним списком. Пример такого списка показан на рисунке 3.7.

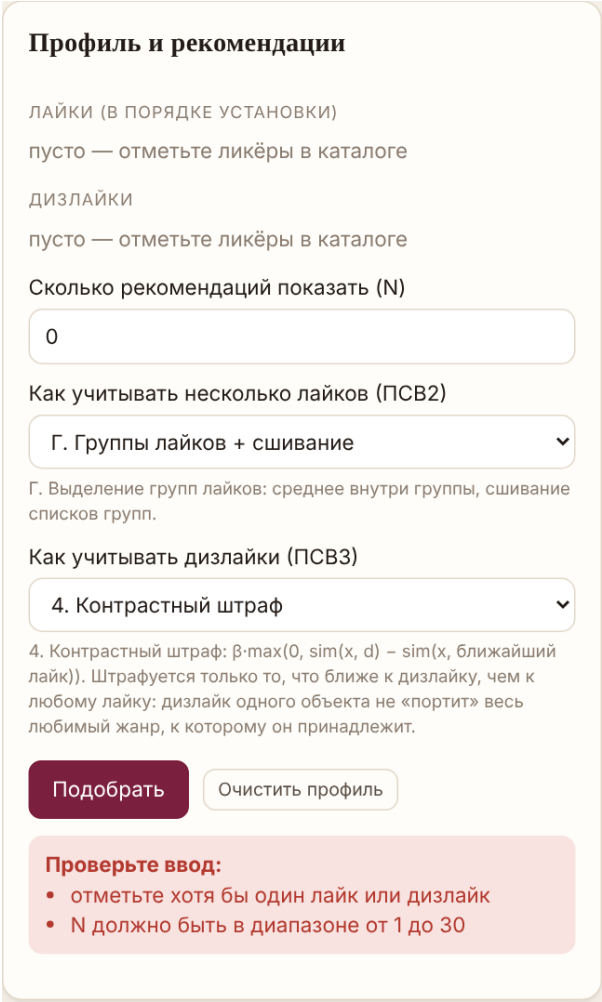


Рисунок 3.7 – Сообщения об ошибках ввода для пустого профиля и $N = 0$

Выводы

Разработана контентная рекомендательная система в трёх версиях с веб-интерфейсом. Для PCv2 сравнены шесть подходов и выбран подход Г «группы лайков со сшиванием» с порогом $\theta = 0{,}65$. При трёх интересах он даёт наибольшие recall(5), 0,797, и coverage(5), 1,0. Для PCv3 сравнены четыре политики учёта дизлайков и выбран контрастный штраф с $\beta = 1$. Он втрое снижает утечку нелюбимого стиля и почти не портит любимый жанр. Каждая рекомендация сопровождается объяснением. Рекомендательное ядро использовано в ЛР4 без изменений.

4 Поиск и объединённая система (ЛР4, РК1)

4.1 Постановка задачи

Рекомендательная система отвечает на вопрос «что ещё мне может понравиться». Пользователь, который знает, что ему нужно, формулирует ограничения сам вроде «травяной, не крепче 30 %, итальянский». ЛР4 добавляет такой **параметрический поиск**. Пользователь задаёт ограничения по фильтрам, любую их часть, и получает выборку подходящих объектов. Если выборка пуста, система не должна отвечать пустым экраном. Она выдаёт объекты с формулировкой «не найдено точного соответствия, однако, возможно, Вам понравится».

РК1 объединяет поиск и рекомендации в одну систему с общим интерфейсом. Нужно фильтровать полученные рекомендации и хранить историю запросов. Тогда можно уточнять результат предыдущего поиска или запроса рекомендаций либо начинать заново. Работа идёт по циклу «поиск → рекомендации → поиск → . . . ».

4.2 Выбор фильтров

Набор фильтров повторяет то, что пользователь видит в каталогах крупных интернет-магазинов. Это категория, у нас дерево вкусов, бренд, страна, числовые диапазоны вместо цены, характеристики-флаги и строка поиска по названию. Каждый признак датасета из ЛР1, кроме служебных, представлен фильтром подходящего типа в таблице 4.1.

Таблица 4.1 – Фильтры поиска

Фильтр	Элемент формы	Степень соответствия $\deg_f(x)$	Вес w_f	Ослабление
Название	строка	1 за подстроку, иначе нечёткое совпадение $\geq 0{,}7$ или 0	3	снять
Вкус	дерево с флажками L1, L2, L3	доля общего пути с ближайшим выбранным узлом	3	подняться к родителю
Крепость, сахар	«от» и «до»	1 внутри, линейно до 0 при выходе на 25 % размаха	2	расширить на 10 % размаха
Горечь	да / нет / неважно	1 или 0	1,5	снять
Класс сладости	флажки термов	1− расстояние до ближайшего терма/3	1	добавить соседние термы
Дерево, страна, производитель	переключатель, флажки	1 или 0	1	снять
Объём	«от» и «до»	как у крепости	0,5	расширить

Семантика запроса. Разные фильтры объединяются конъюнкцией, то есть логическим И. Значения внутри одного фильтра объединяются дизъюнкцией, например «Франция или Италия» и «амаро или кройтер». Незаданный фильтр ограничений не накладывает, а пустой запрос возвращает весь каталог. Такая семантика привычна по интернет-магазинам. Запрос — конъюнкция фильтров.

Принятые решения по отдельным фильтрам приведены ниже.

— **Вкус задаётся узлами дерева, а не только листьями.** Выбор узла «Травяные» включает всё поддерево. Пользователь может быть точным и выбрать «амаро» или общим и выбрать «что-нибудь травяное», не отмечая все листья вручную.

— **Текстовый поиск** не учитывает регистр и диакритику. Запрос «KAHLUA» находит «Kahlúa», а «creme» — «Crème». При опечатке включается нечёткое совпадение по коэффициенту `difflib.SequenceMatcher`. Например, «kalua» находит Kahlúa со степенью 0,8. Порог 0,7 отсекает случайные совпадения. Без него «kalua» получал степень 0,6 с девятью посторонними объектами.

— **Сладость доступна двумя способами.** Это точный диапазон в граммах на литр и слова через лингвистическую переменную из ЛР1. Покупатель редко знает содержание сахара в граммах.

4.3 Проверка корректности ввода

Каждое поле формы проверяется независимо. Ошибки всех полей собираются в один ответ, чтобы пользователь исправил всё за один раз. Проверяется следующее.

— Числа диапазонов. Допускается и десятичная запятая, и точка. Строки «10x», «nan» и «inf» отклоняются регулярным выражением.

— Физические границы. Крепость от 0 до 100 %, сахар от 0 до 1000 г/л, объём от 0,05 до 5 л. Значение «от» не больше значения «до».

— Узлы вкуса, страны, производители и термы. Принимаются только значения из справочников каталога.

— Трёхзначные флаги принимают только `any`, `yes` и `no`. Длина строки поиска не больше 100 символов. Типы полей проверяются явно.

Границы, выходящие за значения датасета, но физически возможные, ошибкой не считаются. Крепость 60 % физически возможна, хотя в датасете её нет. Такой запрос просто не найдёт точных совпадений, и сработает механизм из раздела 4.4.

4.4 Пустая выдача: «возможно, Вам понравится»

4.4.1 Рассмотренные подходы

Задание допускает два пути. Можно использовать механизм рекомендаций или отодвинуть слишком строгие границы фильтров.

1. **Рекомендации по профилю.** Не подходят как основной механизм. У пользователя может не быть ни одного лайка, а рекомендации не учитывают сам запрос.

2. **Ослабление фильтров** по схеме query relaxation [18]. Реализован жадный алгоритм `RelaxationAdvisor`. На каждом шаге пробуется ослабить каждый фильтр на один шаг из таблицы 4.1. Выбирается вариант, который даёт точные совпадения, а при их отсутствии сильнее всего повышает лучшую степень соответствия. При равенстве выбирается вариант с меньшей ценой. Ценой считается вес фильтра, а для расширения — половина веса. Подход объясним и говорит «ослабьте крепость до 19 %». Однако он выдаёт только объекты, прошедшие ослабленный запрос. Ослабленное ограничение снимается целиком для всех объектов, даже если искомый объект нарушал другое.

3. **Функция полезности** как мягкие ограничения [19]. Каждый объект получает степень соответствия запросу

$$U(x) = \frac{\sum_f w_f \deg_f(x)}{\sum_f w_f}, \tag{4.1}$$

Это очки за выполненные фильтры и штраф за нарушенные. Штраф пропорционален расстоянию до границы. Объекты ранжируются по $U(x)$. Нарушение на 1 % крепости почти не штрафуется, а нарушение на 20 % — полностью. Нарушение узла вкуса оценивается по общему пути в дереве, как в мере ЛР2. «Кройтер» вместо «амаро» получает $2/3$.

4.4.2 Сравнение стратегий

Использован протокол «восстановления задуманного объекта». Для каждого ликёра x строится запрос из его группы L2, класса сладости и флага дерева. Затем два ограничения из четырёх портятся. Крепость сдвигается на 3–8 п. п., сахар — на 20–60 г/л, страна заменяется, а горечь инвертируется. В результате точных совпадений нет. Так моделируется пользователь, который неточно помнит параметры. Получено 179 сценариев из 6 пар искажений для 30 объектов без сценариев, где точные совпадения остались. Метрика $\mathrm{Hit}(k)$ — доля сценариев, в которых x оказался среди

первых k.

Таблица 4.2 – Восстановление задуманного объекта при пустой выдаче. Всего 179 сценариев

Стратегия	Hit(1)	Hit(5)
ослабление фильтров, выдача по ослабленному запросу	0,603	0,698
функция полезности $U(x)$	**0,637**	**1,000**

Функция полезности ни разу не потеряла задуманный объект из первой пятёрки, что видно из таблицы 4.2. Ослабление теряет его в 30 % сценариев. Жадный алгоритм снимает ограничение, которое мешало другому объекту, и выдача уходит в сторону. В 8,9 % сценариев ослабление предлагало расширить вкус, то есть самое важное ограничение. Поэтому принято комбинированное решение. **Выдача «возможно, Вам понравится» ранжируется функцией полезности**, а результат `RelaxationAdvisor` показывается как подсказка. Пользователь видит, какие ограничения достаточно ослабить, чтобы появились точные совпадения, и сколько их будет, как на рисунке 4.3. Рядом с каждым объектом указываются невыполненные фильтры и степень их выполнения.

4.5 Объединённая система (PK1)

4.5.1 Сценарий работы

Объединённая система в каталоге `4-search` использует рекомендательное ядро ЛР3 без копирования. Пакет `recsys` подключается из каталога `3-likesdislikes` как есть. Сценарий работы показан на рисунке 4.1.

— **Поиск** — новый запрос фильтров по всему каталогу.

— **Лайк и дизлайк** доступны на любой карточке любой выдачи. Профиль хранится в сессии и не теряется между шагами.

— **Рекомендации** строятся по профилю сессии. Версия выбирается автоматически. Одна затравка — v1, только лайки — v2, есть дизлайки — v3. Область рекомендаций — весь каталог или текущая

выдача по принципу «порекомендуй среди найденного». Флажок «отфильтровать рекомендации» применяет фильтры формы к рекомендациям.

— **Уточнение** применяет фильтры к результатам текущего шага и сохраняет их порядок и объяснения.

— **История** сохраняет каждый шаг. Щелчок по шагу возвращает его результат и восстанавливает форму фильтров. После этого уточнять можно уже от него. Кнопки «Начать заново» и «Сбросить всё» начинают работу с чистого листа. Первая очищает историю, но оставляет профиль.

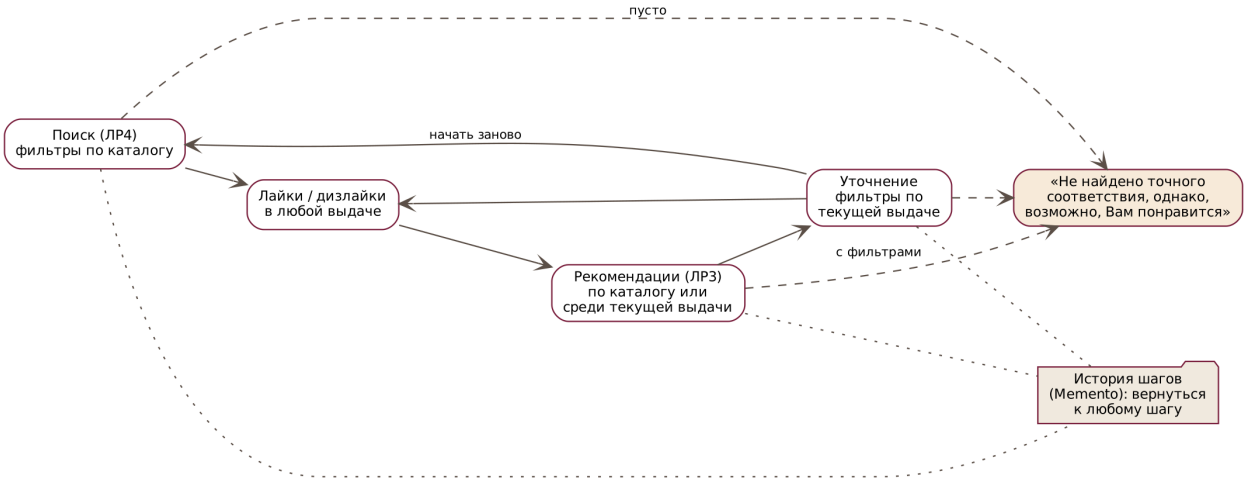


Рисунок 4.1 – Цикл работы объединённой системы

4.5.2 Функция полезности для фильтрации рекомендаций

Когда фильтруются рекомендации, у объекта две оценки. Это релевантность рекомендателя $r(x)$ и степень соответствия фильтрам $U(x)$. Итоговая полезность

$$S(x) = U(x) \cdot \big((1-\lambda) + \lambda\, r(x)\big), \qquad \lambda = 0{,}5. \tag{4.2}$$

Если есть точные совпадения с $U = 1$, они показываются в порядке рекомендателя. Порядок групп интересов из ЛР3 при этом сохраняется. Если

точных совпадений нет, объекты ранжируются по $S(x)$. Выбрано произведение, а не сумма. Объект должен быть хорош по обоим критериям, и сильная рекомендация не компенсирует полное нарушение фильтров. При $U = 0$ значение S тоже равно нулю. При $\lambda = 0{,}5$ релевантность может изменить оценку не более чем вдвое. Фильтры остаются главными, потому что пользователь задал их явно. Рекомендации же упорядочивают объекты внутри одинаково подходящих.

4.6 Пользовательский интерфейс

Экран разделён на три колонки. Слева форма фильтров, в центре выдача текущего шага, справа профиль, параметры рекомендаций и история. Ниже показан сквозной сценарий.

На рисунке 4.2 показан поиск по фильтрам «фруктовые, крепость 20–30 %».

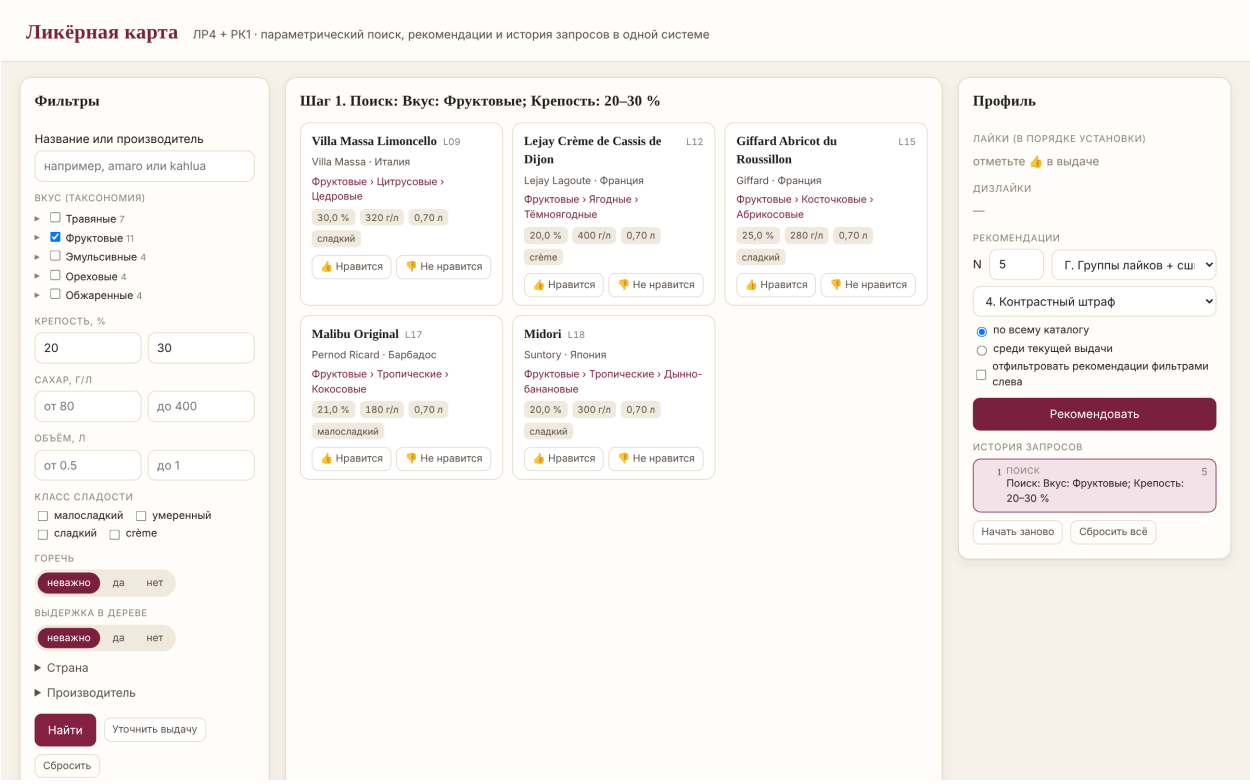


Рисунок 4.2 – Шаг 1. Поиск фруктовых ликёров крепостью 20–30 %

На рисунке 4.3 точных совпадений нет. Объекты ранжированы функцией полезности, у каждого указаны невыполненные фильтры. Подсказка

предлагает снять горечь и расширить крепость до 19 %.

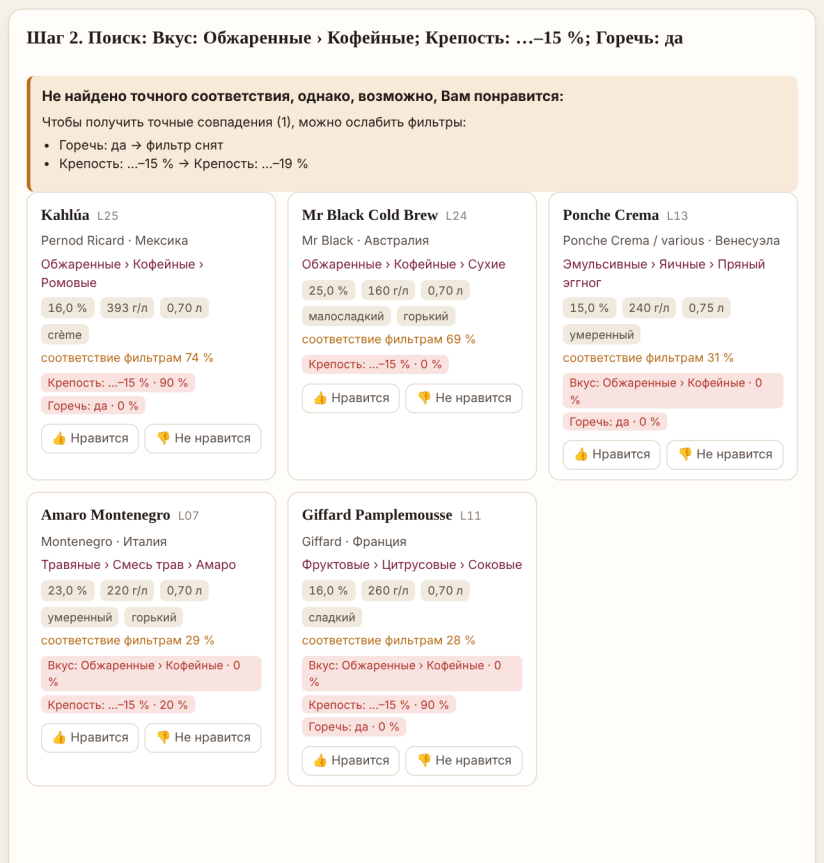


Рисунок 4.3 – Шаг 2. Пустая выдача для запроса «кофейные, не крепче 15 %, горькие». Ранжирование функцией полезности, невыполненные фильтры и подсказка ослабления

На рисунке 4.4 пользователь поставил два лайка и один дизлайк прямо на карточках выдачи. Справа построены рекомендации версии v3.

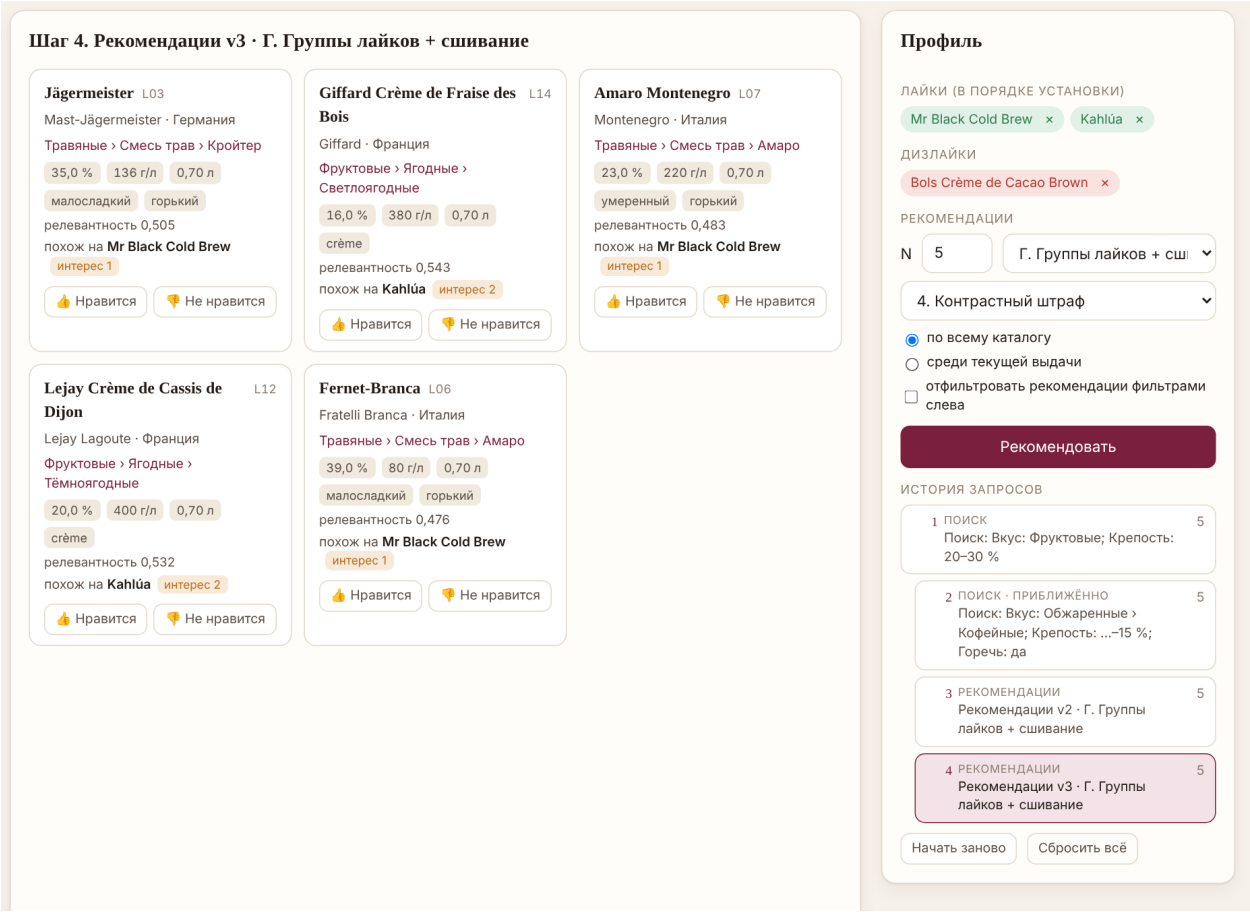


Рисунок 4.4 – Шаги 3–4. Лайки Mr Black и Kahlúa из выдачи, дизлайк Crème de Cacao Brown, рекомендации v3

На рисунке 4.5 рекомендации уточнены фильтром «сахар не более 300 г/л». Объяснения рекомендаций при этом сохранены.

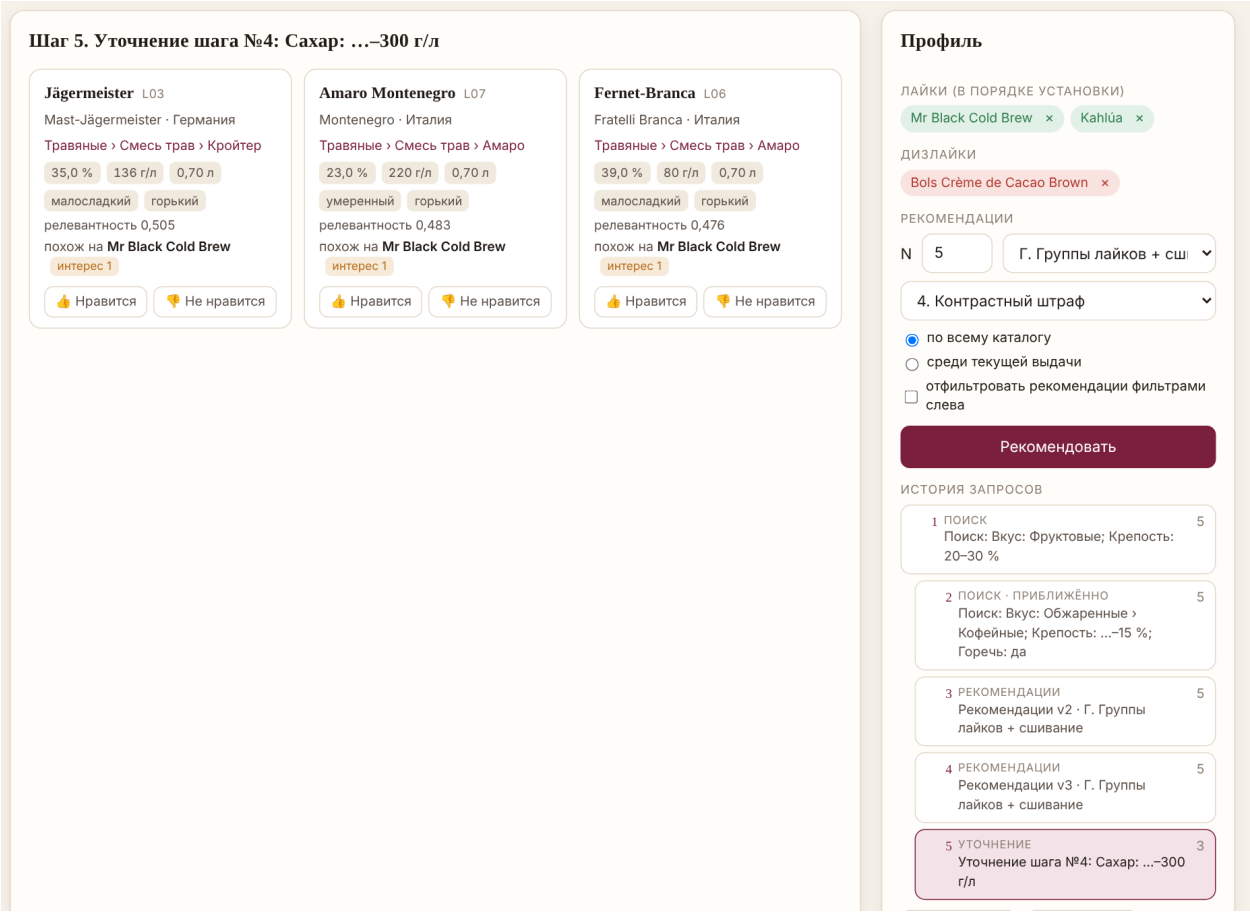


Рисунок 4.5 – Шаг 5. Уточнение рекомендаций фильтром «сахар не более 300 г/л». Объяснения рекомендаций сохранены

На рисунке 4.6 рекомендации построены по всему каталогу и отфильтрованы условиями «Франция, крепость от 30 %».

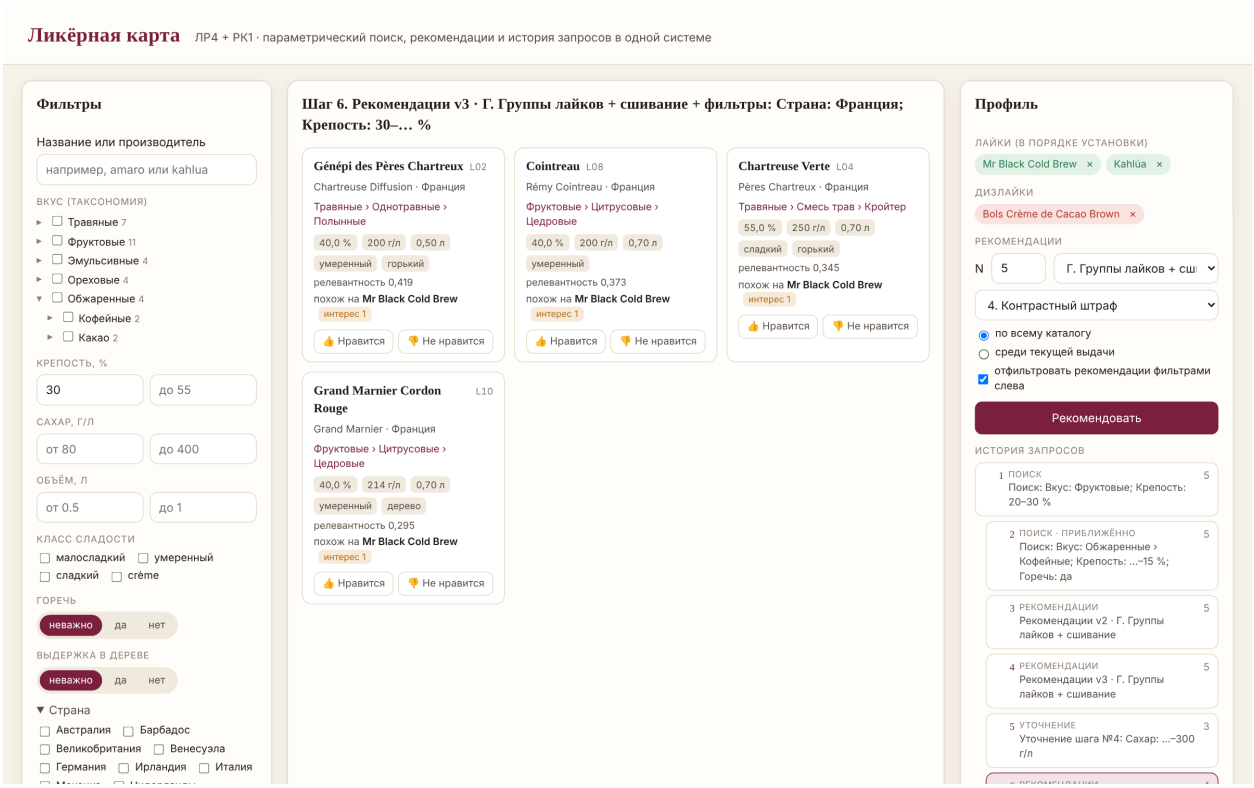


Рисунок 4.6 – Шаг 6. Рекомендации по всему каталогу, отфильтрованные условиями «Франция, крепость от 30 %»

На рисунке 4.7 показан возврат к первому шагу через историю. Выдача и форма фильтров восстановлены.

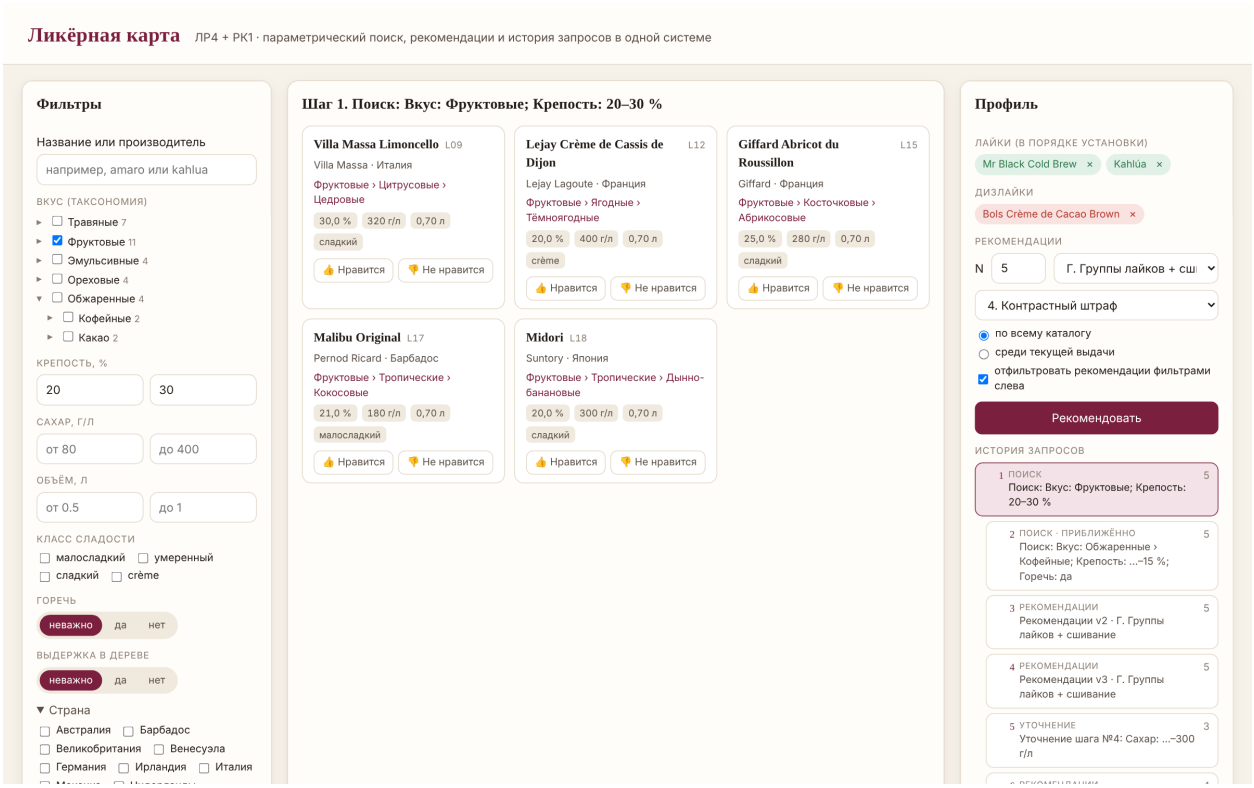


Рисунок 4.7 – Возврат к шагу 1 через историю. Восстановлены выдача и форма фильтров

Ввод проверяется на сервере, и все ошибки возвращаются одним списком. Пример показан на рисунке 4.8.

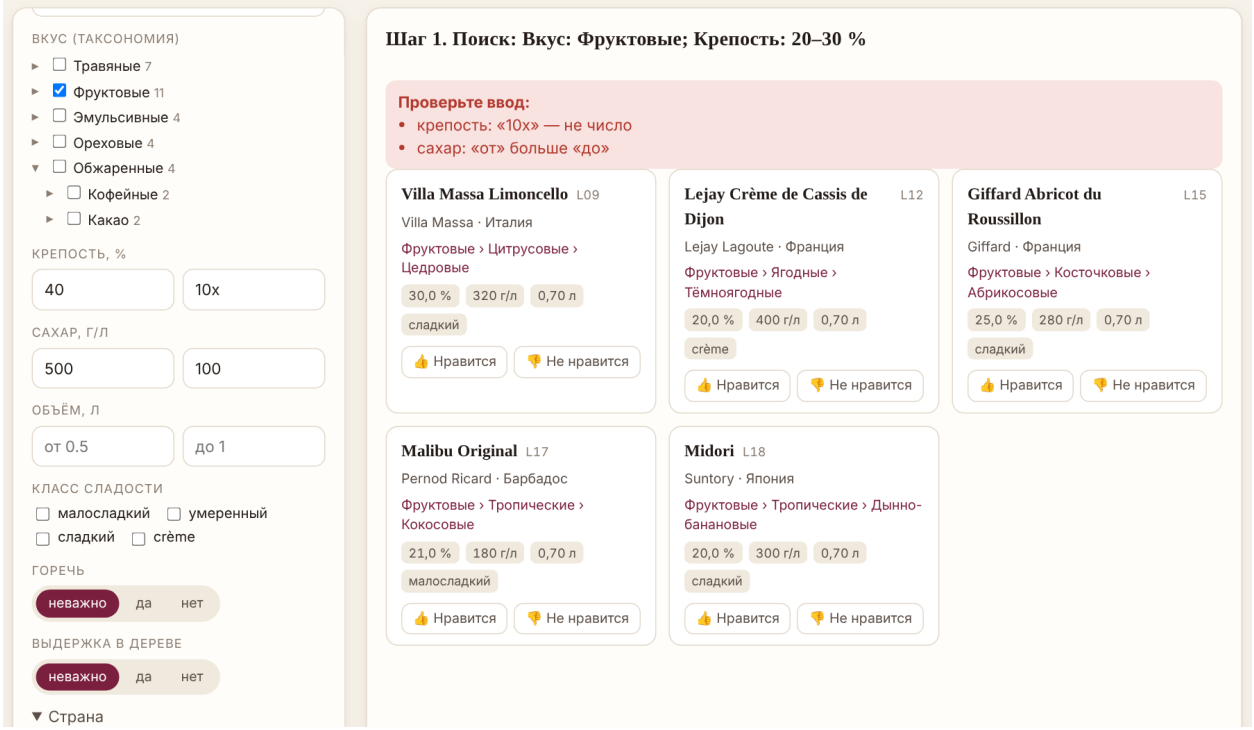


Рисунок 4.8 – Ошибки ввода. Все нарушения формы показаны одним списком

Выводы

Реализован параметрический поиск по десяти фильтрам всех типов признаков с проверкой ввода. Для пустой выдачи выбрана функция полезности. Она восстанавливает задуманный объект в первой пятёрке во всех 179 тестовых сценариях, а ослабление фильтров — только в 70 %. Ослабление используется как подсказка пользователю. Поиск и рекомендации ЛР3 объединены в систему с общим интерфейсом, сессионным профилем, фильтрацией рекомендаций по функции полезности (4.2) и историей шагов. К любому шагу можно вернуться для уточнения или начать работу заново.

5 Сценарии диалога (ЛР5)

5.1 Постановка задачи

Начиная с ЛР5 курс строит диалоговую систему. Пользователь задаёт вопрос на русском языке, а система отвечает или выполняет запрос к рекомендательной системе из ЛР3–ЛР4. Тема диалога остаётся прежней — ликёры. Поэтому диалоговая система станет новым интерфейсом к уже готовым данным и алгоритмам.

ЛР5 готовит сценарии беседы для такой системы. Требуется:

— выделить классы вопросов, которые пользователь задаёт на эту тему;

— подготовить не менее пяти вопросов каждого класса;

— переформулировать каждый вопрос двумя-тремя способами;

— определить опорные слова, по которым узнаётся класс вопроса;

— записать шаблоны фраз с местозаменителями и расшифровать их;

— задать вежливый ответ по шаблону на вопросы, на которые ответить нельзя.

Корпус вопросов, словари и проверка хранятся в каталоге `5-dialogue` репозитория.

5.2 Классы вопросов

Классы выбраны по тому, какая часть системы должна ответить на вопрос (таблица 5.1). Тогда класс вопроса сразу определяет обработчик ответа. Справку о домене даёт датасет ЛР1, подбор выполняют рекомендатель ЛР3 и поиск ЛР4, сравнение опирается на меру близости ЛР2.

Таблица 5.1 – Классы вопросов диалоговой системы

№	Класс	Что спрашивают	Источник ответа
1	о предметной области	что такое ликёр, крепость, состав, виды ликёров, состав коктейля	датасет ЛР1, таксономия вкуса, база коктейлей
2	о функциональности системы	что система умеет и чего не умеет	справка о возможностях
3	поиск и рекомендации	что похоже на ликёр, что найти по условиям, что добавить в кофе или коктейль, с чем смешать	рекомендатель ЛР3, поиск ЛР4, база коктейлей
4	сравнение двух объектов	чем один ликёр отличается от другого, что слаще или крепче	мера близости ЛР2 и вклады признаков
5	изменение состава системы	добавить, удалить или изменить ликёр, вкусовую группу, коктейль	команды правки данных
6	нельзя дать ответ	цены и магазины, погода, дозы алкоголя и здоровье, факты вне базы	вежливый ответ по шаблону

Границы классов проведены по нескольким правилам.

— **Коктейли разделены между классами 1 и 3.** Вопрос «из чего состоит B-52» просит знание о домене, ответ на него не зависит от вкуса пользователя. Вопросы «какой ликёр добавить в кофе», «чем заменить Cointreau в Маргарите» и «с чем смешать Malibu» просят подбор. На них отвечает рекомендатель с учётом базы коктейлей.

— **Сравнение выделено в отдельный класс.** В вопросе два конкретных ликёра, а ответ строится по мере близости ЛР2 и её вкладам. Рекомендация, наоборот, отталкивается от одного образца или от ограничений.

— **Вопрос о возможности — класс 2, а не просьба.** «Ты умеешь подбирать ликёры?» спрашивает о системе. Ответ на него — справка, а не список ликёров.

— **Класс 6 включает вопросы о дозах алкоголя и о здоровье.** Данные для них в системе есть только частично, например крепость. Совет о том, сколько можно выпить или можно ли пить при болезни, рекомендательная система давать не должна.

Для вопросов о коктейлях подготовлена база `cocktails.json`. В ней девять коктейлей с ликёрами каталога, например B-52, Белый русский, Эспрессо-мартини, Маргарита и Кузнечик. Там же указаны миксеры, с

которыми ликёры обычно смешивают, например Malibu с ананасовым соком, Fernet-Branca с колой и Kahlúa с молоком. Ликёры в базе указаны идентификаторами датасета, поэтому подбор замены в коктейле может использовать меру близости ЛР2.

На рисунке 5.1 показано, как вопрос будет проходить через диалоговую систему. ЛР5 реализует левую часть схемы до выбора класса. Обработчики классов строятся в следующих работах.

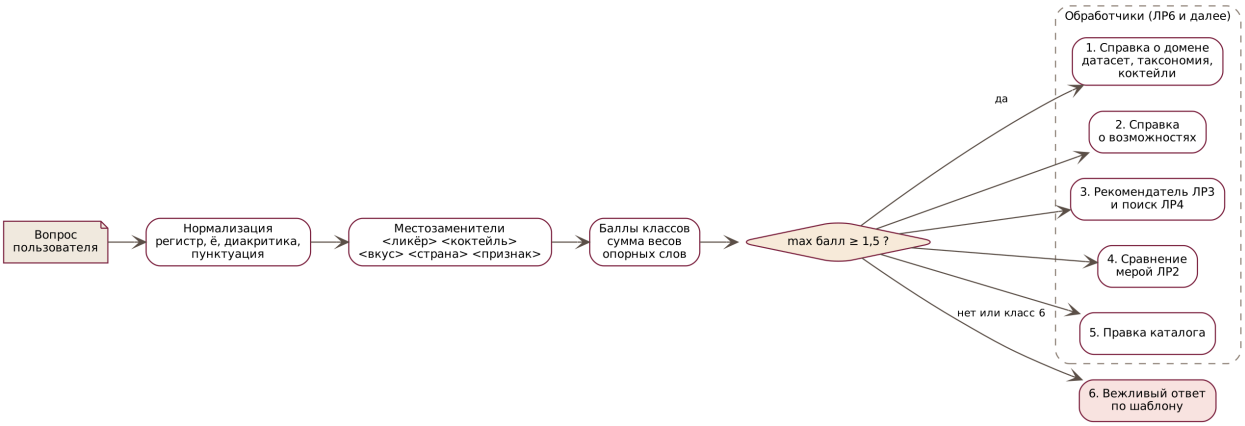


Рисунок 5.1 – Обработка вопроса: от текста к классу и обработчику

5.3 Вопросы и переформулировки

Корпус содержит 37 исходных вопросов, от шести до семи в каждом классе, и по три переформулировки каждого вопроса. Всего 148 формулировок (таблицы 5.2–5.7). Переформулировки построены несколькими способами, чтобы проверить разные явления живой речи:

— замена вопросительного слова и порядка слов: «Какая крепость у Jägermeister?» и «Насколько крепкий Jägermeister?»;

— синонимы и близкие глаголы: «посоветуй», «подбери», «найди», «что ещё попробовать»;

— разное написание названий: Baileys и Бейлиз, Jägermeister, Егермейстер и Егерь;

— разговорные и неполные фразы: «Фернет нравится, Jägermeister нет — подбери что-нибудь»;

— перенос смысла в другую часть речи: «сравни сладость» вместо «что слаще».

5.3.1 Класс 1. Вопросы о предметной области

Таблица 5.2 – Вопросы класса 1 и их переформулировки

№	Вопрос	Переформулировки
1.1	Что такое ликёр?	— Чем ликёр отличается от обычного крепкого алкоголя? — Объясни, что называют ликёром. — Какой напиток можно назвать ликёром?
1.2	Какая крепость у Jägermeister?	— Сколько градусов в Егермейстере? — Насколько крепкий Jägermeister? — Подскажи процент алкоголя в Jägermeister.
1.3	Какие бывают виды ликёров по вкусу?	— На какие группы делятся ликёры? — Какие вкусовые категории ликёров ты знаешь? — Перечисли типы ликёров.
1.4	Из чего делают Baileys?	— На какой основе сделан Бейлиз? — Что входит в состав Baileys? — Baileys — это ликёр на чём?
1.5	Что такое амаро?	— Какие ликёры относятся к амаро? — Расскажи про категорию амаро. — Чем характерны амаро?
1.6	Какие ликёры входят в коктейль B-52?	— Из каких ликёров состоит Б-52? — Что нужно для коктейля Б-52? — Какой состав у шота B-52?

5.3.2 Класс 2. Вопросы о функциональности системы

Таблица 5.3 – Вопросы класса 2 и их переформулировки

№	Вопрос	Переформулировки
2.1	Что ты умеешь?	— Какие у тебя функции? — Чем ты можешь мне помочь? — Что можно у тебя спросить?
2.2	Ты можешь подобрать ликёр по моим предпочтениям?	— Ты умеешь давать рекомендации? — Умеешь советовать ликёры по вкусу? — Ты рекомендуешь напитки по лайкам?

Продолжение таблицы 5.3

№	Вопрос	Переформулировки
2.3	Ты можешь заказать мне бутылку?	— Умеешь ли ты оформлять покупки? — Можно через тебя купить ликёр? — Ты продаёшь ликёры?
2.4	Сколько ликёров есть в твоей базе?	— Какой у тебя каталог? — Со сколькими ликёрами ты работаешь? — Насколько большая у тебя база ликёров?
2.5	По каким параметрам можно искать?	— Какие фильтры поиска ты поддерживаешь? — По каким признакам ты ищешь ликёры? — Что можно указать в запросе на поиск?
2.6	Как ты учитываешь мои дизлайки?	— Что ты делаешь с ликёрами, которые мне не понравились? — Как дизлайки влияют на твои советы? — Зачем тебе знать, что мне не нравится?

5.3.3 Класс 3. Вопросы на поиск и рекомендации

Таблица 5.4 – Вопросы класса 3 и их переформулировки

№	Вопрос	Переформулировки
3.1	Посоветуй что-нибудь похожее на Baileys.	— Что ещё мне может понравиться, если я люблю Бейлиз? — Найди ликёр в стиле Baileys. — Какой ликёр похож на Baileys?
3.2	Найди травяной ликёр крепче 30 градусов.	— Покажи травяные ликёры от 30 %. — Есть ли травяной ликёр крепостью больше 30? — Хочу травяной ликёр не слабее 30 градусов.
3.3	Подбери сладкий ликёр из Италии.	— Какие сладкие итальянские ликёры есть? — Покажи итальянские ликёры с высоким содержанием сахара. — Хочу что-нибудь сладкое итальянское.
3.4	Мне понравился Fernet-Branca, но не понравился Jägermeister. Что посоветуешь?	— Люблю Фернет, а Егермейстер не нравится. Что ещё попробовать? — Фернет нравится, Jägermeister нет — подбери что-нибудь. — Что выбрать, если Fernet понравился, а Егерь нет?
3.5	Какой ликёр добавить в кофе?	— Что подлить в кофе из ликёров? — Посоветуй ликёр к кофе. — Какой ликёр подойдёт для кофе?

Продолжение таблицы 5.4

№	Вопрос	Переформулировки
3.6	Чем заменить Cointreau в Маргарите?	— Что можно взять вместо Куантро для Маргариты? — Какой ликёр подойдёт в Маргариту, если нет Cointreau? — Нет Куантро, что положить в Маргариту?
3.7	С чем смешать Malibu?	— С чем пить Малибу? — Что миксовать с Malibu? — С каким соком сочетается Malibu?

5.3.4 Класс 4. Вопросы на сравнение двух объектов

Таблица 5.5 – Вопросы класса 4 и их переформулировки

№	Вопрос	Переформулировки
4.1	Чем Cointreau отличается от Grand Marnier?	— В чём разница между Куантро и Гран Марнье? — Cointreau или Grand Marnier: какой взять? — Сравни Cointreau и Grand Marnier.
4.2	Что слаще: Baileys или Amarula?	— Какой из них слаще, Бейлиз или Амарула? — В каком больше сахара, Baileys или Amarula? — Сравни сладость Baileys и Amarula.
4.3	Насколько похожи Jägermeister и Fernet-Branca?	— Похож ли Егермейстер на Фернет? — Близки ли Jägermeister и Fernet по вкусу? — Насколько Fernet-Branca похож на Jägermeister?
4.4	Какой крепче: Chartreuse Verte или Génépi?	— Что крепче, Шартрез или Женепи? — В каком больше градусов, Chartreuse или Génépi? — Сравни крепость Шартреза и Женепи.
4.5	Disaronno и Luxardo Amaretto — это одно и то же?	— Есть ли разница между Дисаронно и Луксардо Амаретто? — Disaronno и Luxardo одинаковые? — Отличается ли Disaronno от Luxardo Amaretto?
4.6	Kahlúa или Mr Black: что лучше для эспрессо-мартини?	— Для эспрессо-мартини лучше Калуа или Мистер Блэк? — Что выбрать в эспрессо-мартини: Kahlúa или Mr Black? — Сравни Kahlúa и Mr Black для эспрессо-мартини.

5.3.5 Класс 5. Вопросы на изменение состава системы

Таблица 5.6 – Вопросы класса 5 и их переформулировки

№	Вопрос	Переформулировки
5.1	Добавь в каталог ликёр Aperol.	— Внеси Aperol в базу. — Хочу добавить новый ликёр Aperol. — Запиши Апероль в список ликёров.
5.2	Удали Midori из базы.	— Убери Мидори из каталога. — Исключи Midori из списка ликёров. — Midori больше не нужен в базе, сотри его.
5.3	Измени крепость Kahlúa на 20 %.	— Поправь крепость Калуа: 20 градусов. — У Kahlúa теперь 20 %, обнови данные. — Установи для Kahlúa крепость 20.
5.4	Отметь, что Frangelico выдерживается в дереве.	— У Frangelico есть контакт с деревом, исправь. — Поставь Франжелико признак выдержки в дереве. — Frangelico выдерживают в бочке, учти это.
5.5	Добавь в таксономию новую вкусовую группу «Медовые».	— Создай вкусовую категорию «Медовые». — Нужна новая ветка «Медовые» в классификации вкусов. — Заведи группу вкуса «Медовые».
5.6	Добавь коктейль Mudslide: водка, Kahlúa и Baileys.	— Запомни новый коктейль Mudslide с Калуа и Бейлиз. — Внеси рецепт Mudslide в базу коктейлей. — Сохрани коктейль Mudslide из Kahlúa, Baileys и водки.

5.3.6 Класс 6. Вопросы, на которые нельзя дать ответ

Таблица 5.7 – Вопросы класса 6 и их переформулировки

№	Вопрос	Переформулировки
6.1	Сколько стоит Baileys?	— Какая цена у Бейлиз? — Почём сейчас Baileys? — Сколько рублей за бутылку Baileys?
6.2	Где купить Chartreuse в Москве?	— В каком магазине продаётся Шартрез? — Где найти Chartreuse поблизости? — Подскажи, где взять Шартрез в Москве.

Продолжение таблицы 5.7

№	Вопрос	Переформулировки
6.3	Какая завтра погода?	— Будет ли завтра дождь? — Сколько градусов будет завтра на улице? — Что с погодой на выходных?
6.4	Сколько ликёра можно выпить, чтобы не опьянеть?	— Сколько рюмок можно выпить и сесть за руль? — Какая доза ликёра безопасна? — Сколько Jägermeister выпить, чтобы не было похмелья?
6.5	Можно ли пить ликёр при простуде?	— Совместим ли Baileys с антибиотиками? — Можно ли ликёр при больном горле? — Помогает ли Fernet от простуды?
6.6	Какой ликёр пил Хемингуэй?	— Какой ликёр любил Хемингуэй? — Что из ликёров предпочитал Хемингуэй? — Хемингуэй пил какой ликёр?

5.4 Местозаменители и шаблоны фраз

Многие вопросы различаются только названием ликёра, вкуса или числом. Такие места шаблона заменены местозаменителями (таблица 5.8). Их значения хранятся в словаре `lexicon.json`. Для каждого ликёра записаны оригинальное название и русские написания, потому что пользователь пишет и «Baileys», и «Бейлиз». Значения хранятся основами. Основа «шартрез» находит и «Шартрез», и «Шартреза», поэтому склонение не мешает поиску.

Таблица 5.8 – Местозаменители шаблонов фраз

Местозаменитель	Значения
⟨ликёр⟩	30 ликёров каталога и их написания: Baileys, Бейлиз, Бейлис; Jägermeister, Егермейстер, Егерь; Cointreau, Куантро и т. д.
⟨коктейль⟩	B-52, Белый русский, Эспрессо-мартини, Mudslide, Маргарита, Космополитен, Кузнечик, Кир, Амаретто сауэр
⟨вкус⟩	узлы таксономии ЛР1: травяной, фруктовый, цитрусовый, ягодный, сливочный, кофейный, амаро, кройтер и др.
⟨страна⟩	страна и прилагательное от неё: Италия, итальянский; Франция, французский и др.
⟨признак⟩	крепость, градус; сахар, сладость; объём; горечь; дерево, бочка, выдержка
⟨число⟩	число с единицей измерения: %, градусов, г/л, л
ge	больше | крепче | выше | от | не меньше | не слабее
le	меньше | слабее | ниже | до | не больше | не крепче
сравн	слаще | крепче | горче | лучше

Шаблоны записаны в нотации регулярных выражений, как в методических указаниях [20]. Квадратные скобки обозначают выбор одного варианта, фигурные — выбор из множества местозаменителей, знак «?» после скобки — необязательную часть.

```
1: [что такое | расскажи про | что называют] {<вкус>|<ликёр>|ликёр} ?
   [какая крепость у | сколько градусов в | насколько крепкий] <ликёр> ?
   [из чего делают | что входит в состав | из каких ликёров состоит]
       {<ликёр>|<коктейль>} ?
2: [что | как] ты [умеешь | можешь | учитываешь] ...?
   [по каким параметрам | какие фильтры] [можно искать | ты поддерживаешь] ?
3: [посоветуй | найди | подбери | хочу] [что-нибудь]
       [похожее на <ликёр> | <вкус> {ge|le} <число> | из <страна>] .
   [какой ликёр | что] [добавить | подлить] [в | к] {кофе|<коктейль>} ?
   [чем заменить | что взять вместо] <ликёр> в <коктейль> ?
   с чем [смешать | пить | миксовать] <ликёр> ?
4: [чем | в чём разница между] <ликёр> [и | от] <ликёр> ?
   [что | какой] {сравн} [:] <ликёр> или <ликёр> ?
   [сравни] (<признак>)? <ликёр> и <ликёр> .
5: [добавь | внеси | удали | убери | измени | отметь | создай]
       {<ликёр>|<вкус>|<коктейль>} [в | из] [каталог | базу | таксономию]
       ([<признак> на <число>])? .
6: вопросы с маркерами цены, магазина, погоды, дозы и здоровья,
   а также вопросы без опорных слов других классов
```

5.5 Опорные слова

Класс вопроса определяется по опорным словам. Это основы слов и словосочетания, характерные для класса, а также условия на число местозаменителей в вопросе. Каждому опорному слову приписан вес. Класс c получает балл

$$B_c(q) = \sum_k w_{ck} \, [\text{правило } k \text{ класса } c \text{ сработало на } q], \tag{5.1}$$

и вопрос относится к классу с наибольшим баллом. Если наибольший балл меньше порога 1,5, вопрос относится к классу 6. Порог равен весу одного слабого признака класса, например упоминания крепости в вопросе о домене. Ниже порога остаются вопросы, в которых нет ни одного уверенного признака известного класса. При равенстве баллов выигрывает класс с

более специфичными опорными словами. Порядок проверки такой: функциональность, нельзя ответить, изменение, сравнение, рекомендации, домен. Итоговые опорные слова приведены в таблице 5.9.

Таблица 5.9 – Опорные слова классов. В скобках — вес

Класс	Опорные слова и условия
1. домен	что такое, расскажи, объясни, назвать (2); из чего, состав, состоит, основа, на чём, нужно для (2); виды, бывают, типы, категории, группы (3); входит, относится (1,5); отличается, разница (1,5); алкоголь, напиток (1); какая крепость, сколько градусов (1,5); есть ⟨коктейль⟩ (1)
2. функциональность	ты, тебя, твой (1,5); глагол 2-го лица на -ешь, -ишь (1); умеешь, можешь (2); функции, помочь, зачем, как ты (1,5); параметры, фильтры, по каким, на поиск (2); лайки, учитываешь (2); твоя база, сколько ликёров (2)
3. поиск и рекомендации	посоветуй, подбери, найди, покажи, хочу, есть ли, что ещё (2); похоже на, в стиле (2); нравится, люблю (2); выбрать (1,5); добавить в, подлить, положить, в кофе (2); заменить, вместо (2,5); смешать, миксовать, сочетается, подойдёт (2,5); ge или le и число (1,5); есть ⟨признак⟩ (1); есть ⟨вкус⟩ или ⟨страна⟩ (0,5)
4. сравнение	два ⟨ликёр⟩ в вопросе (3); сравни, отличается, разница, одно и то же, похожи вместе с ⟨ликёр⟩ (2,5); слаще, крепче, горче, лучше (1); или (1)
5. изменение состава	повелительные глаголы правки: добавь, внеси, удали, убери, измени, обнови, отметь, исправь, создай, заведи, сохрани и др. (3); неопределённая форма этих глаголов (1,5); в каталог, из базы, в таксономию (1,5); новый, теперь (1)
6. нельзя ответить	стоит, цена, почём, рублей (3); купить, магазин, продаётся, где взять (3); погода, дождь, завтра, на улице (3); выпить, опьянеть, руль, доза, похмелье (3); лекарства, простуда, горло, здоровье (3); отсутствие опорных слов других классов

Принятые решения по опорным словам:

— **Основы вместо полных слов.** Русские слова склоняются и спрягаются. Основа «сравн» покрывает «сравни», «сравнить», «сравнение». Лемматизация морфологическим анализатором вроде pymorphy2 точнее, но требует внешней библиотеки. Проверка в разделе 5.7 показала, что основ достаточно для различения классов.

— **Местозаменители — тоже опорные признаки.** Два ликёра в одном вопросе почти всегда означают сравнение, поэтому это условие весит 3. Упоминание страны или вкуса встречается во всех классах, поэтому весит всего 0,5.

— **Обращение к системе отличает класс 2.** Местоимения «ты», «тебя» и глаголы 2-го лица на -ешь, -ишь показывают, что пользова-

тель спрашивает о самой системе. Это морфологический признак, а не список глаголов, поэтому он сработает и на глаголах, которых нет в корпусе.

— **Повелительное наклонение отличает класс 5.** Глаголы «добавь», «удали», «измени» — команды. Неопределённая форма весит меньше, потому что «какой ликёр добавить в кофе» — это просьба о подборе, а не команда изменить каталог.

— **Слова сравнения работают только вместе с ликёром.** «Чем ликёр отличается от крепкого алкоголя» — вопрос о домене, а не сравнение двух объектов. Поэтому правило «отличается» класса 4 срабатывает, только если в вопросе есть хотя бы один ⟨ликёр⟩.

— **Маркеры класса 6 весят больше всех.** Слова цены, погоды и здоровья однозначно показывают, что ответа в базе нет. Если на вопрос «Сколько стоит Baileys?» отвечать как на вопрос о домене, получится справка о крепости Baileys вместо честного «цен в базе нет».

5.6 Вежливый ответ по шаблону

На вопросы класса 6 система отвечает по шаблону «извинение + причина + что система может предложить». Причина выбирается по тем же опорным словам (таблица 5.10). Ответ не обрывает разговор. Он объясняет, почему ответа нет, и предлагает вопрос, на который система ответит.

Таблица 5.10 – Вежливые ответы на вопросы, на которые нельзя ответить

Причина	Пример вопроса	Ответ
нет цен и магазинов	Сколько стоит Baileys?	Извините, в моей базе нет цен и сведений о магазинах. Я могу рассказать о вкусе, крепости и сладости этого ликёра или подобрать похожий.
вне темы	Какая завтра погода?	Извините, я отвечаю только на вопросы о ликёрах. Спросите, например: «Посоветуй что-нибудь похожее на Baileys».
здоровье и дозы	Сколько ликёра можно выпить, чтобы не опьянеть?	Извините, я не даю советов о количестве алкоголя и о том, как он сочетается с лекарствами и здоровьем. С такими вопросами лучше обратиться к врачу. Я могу рассказать о крепости, сладости и вкусе ликёров.
нет сведений	Какой ликёр пил Хемингуэй?	Извините, таких сведений нет в моей базе, поэтому ответить я не могу. Я знаю вкус, крепость, сладость и состав коктейлей для 30 ликёров каталога и могу подобрать ликёр по вашему вкусу.

Вопрос о Хемингуэе показывает, зачем нужна причина по умолчанию. В нём есть слово $<\langle$ликёр$\rangle>$, но нет ни одного опорного слова другого класса, и балл не достигает порога. Система не знает ответа и честно говорит об этом.

5.7 Проверка опорных слов

Опорные слова нужно проверить: по ним должен правильно определяться класс не только исходных вопросов, но и новых формулировок. Для проверки реализован классификатор по формуле (5.1). Он прогоняет все формулировки корпуса и сравнивает найденный класс с эталонным. Проверка шла в две итерации.

1. **Первая итерация.** Опорные слова составлены только по 37 исходным вопросам. Переформулировки для неё — новые фразы. Поэтому точность на них показывает, насколько опорные слова переносятся на другие формулировки.

2. **Вторая итерация.** Ошибки первой итерации показали, каких слов не хватает. Добавлены глаголы 2-го лица («рекомендуешь», «продаёшь»), слова состава («состоит», «нужно для»), связка слов сравнения с упоминанием ликёра и неопределённая форма глаголов правки. Эти опорные слова уже настроены с учётом переформулировок.

После настройки написаны 12 контрольных фраз, по две на класс. В настройке они не участвовали, поэтому показывают поведение на действительно новых вопросах. Результаты приведены в таблице 5.11.

Таблица 5.11 – Доля правильно классифицированных формулировок

Набор формулировок	Первая итерация	Итоговые опорные слова
исходные вопросы	37/37	37/37
переформулировки	95/111	110/111
контрольные фразы	10/12	11/12

Первая итерация верно классифицировала 86 % переформулировок. Больше всего ошибок пришлось на класс 2: 11 из 18. Вопросы о возможностях системы часто не содержат слов «умеешь» или «можешь», например «Ты продаёшь ликёры?» или «Со сколькими ликёрами ты работаешь?». Их узнаёт признак глагола 2-го лица, добавленный во второй итерации. Итоговые опорные слова ошибаются на одной переформулировке и одной контрольной фразе (таблица 5.12).

— «Можно через тебя купить ликёр?» отнесён к классу 6 вместо класса 2. Слово «купить» весит больше местоимения «тебя». Опорные слова не показывают, кто совершает действие. Различить «купить через систему» и «купить в магазине» поможет синтаксический разбор, который понадобится в следующих работах.

— «Поменяй страну у Amarula на ЮАР» отнесён к классу 6 вместо класса 5. Глагола «поменяй» нет в списке опорных слов. Словарь синонимов глаголов правки нужно пополнять по мере появления новых формулировок.

Таблица 5.12 – Матрица ошибок итоговых опорных слов на всех 160 формулировках. Строки — эталонный класс, столбцы — найденный

Класс	1	2	3	4	5	6
1. домен	26	0	0	0	0	0
2. функциональность	0	25	0	0	0	1
3. поиск и рекомендации	0	0	30	0	0	0
4. сравнение	0	0	0	26	0	0
5. изменение состава	0	0	0	0	25	1
6. нельзя ответить	0	0	0	0	0	26

Обе ошибки уходят в класс 6. Это безопасное направление ошибки: система не выполнит лишнюю команду и не выдаст неверную справку, а вежливо скажет, что не поняла вопрос. Ошибок между классами 1–5 нет.

Выводы

Для диалоговой системы о ликёрах выделены шесть классов вопросов по тому, какая часть системы на них отвечает. Подготовлены 37 вопросов, от шести до семи в классе, и по три переформулировки каждого. Вопросы о коктейлях разделены между справкой о домене и подбором. Для них составлена база из девяти коктейлей и миксеров. Записаны местозаменители и шаблоны фраз, опорные слова с весами и шаблон вежливого ответа с четырьмя причинами отказа. Проверка показала, что опорные слова верно определяют класс 147 из 148 формулировок корпуса и 11 из 12 новых фраз. Оставшиеся ошибки уходят в безопасный класс 6 и указывают, что дальше понадобятся синтаксический разбор и пополнение словаря синонимов.

ЗАКЛЮЧЕНИЕ

Цель работы достигнута. Разработана рекомендательная система ликёров, объединяющая контентные рекомендации и параметрический поиск. Все проектные решения обоснованы сравнением альтернатив.

В ЛР1 сформирован датасет из 30 ликёров с признаками пяти типов и иерархия предметной области по вкусовой основе. В ней 42 узла классификации при высоте 5 уровней. Деление по вкусу выбрано как смыслообразующее для покупателя. Числовые признаки оставлены атрибутами объектов.

В ЛР2 для каждого типа признаков выбрана частная мера по формальной методике. Она включает матрицы смежности, тепловые карты, эталонные пары, корреляцию ранжирований и зернистость шкалы. Выбраны евклидова мера, SMC, мера У–Палмера, порядковая мера и δ-функция. Обобщающая мера — взвешенная сумма с экспертными весами. Её устойчивость проверена пятью объективными схемами весов.

В ЛР3 разработана контентная РС в трёх версиях. Для набора лайков выбран подход «группы лайков со сшиванием» с $\theta = 0{,}65$. При трёх интересах recall(5) равен 0,797, а покрытие интересов — 100 %. Для сравнения у среднего эти значения равны 0,649 и 74 %. Для дизлайков выбран контрастный штраф. Он втрое снижает утечку нелюбимого стиля и сохраняет любимый жанр. Каждая рекомендация объясняется.

В ЛР4 реализован поиск по десяти фильтрам с проверкой ввода. Пустая выдача заменяется ранжированием по функции полезности. Задуманный объект попадает в первую пятёрку во всех 179 сценариях, а при ослаблении фильтров — только в 70 %. Ослабление используется как подсказка. В РК1 поиск и рекомендации объединены в одну систему с общим интерфейсом, сессионным профилем, фильтрацией рекомендаций и историей шагов.

В ЛР5 подготовлены сценарии беседы для диалоговой системы о ликёрах. Выделены шесть классов вопросов по тому, какая часть системы на них отвечает. Составлены 37 вопросов, по три переформулировки каждого, база коктейлей, местозаменители, шаблоны фраз и шаблон вежливого ответа. Опорные слова верно определяют класс 147 из 148 формулировок корпуса

и 11 из 12 новых фраз.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Lops P. Content-based Recommender Systems: State of the Art and Trends / P. Lops, M. de Gemmis, G. Semeraro // Recommender Systems Handbook / под ред. F. Ricci [и др.]. — Нью-Йорк, США : Springer, 2011. — С. 73—105.
2. Pazzani M. J. Content-Based Recommendation Systems / M. J. Pazzani, D. Billsus // The Adaptive Web. Lecture Notes in Computer Science, vol. 4321. — Берлин, Германия : Springer, 2007. — С. 325—341.
3. Европейский парламент и Совет ЕС. Regulation (EU) 2019/787 on the definition, description, presentation and labelling of spirit drinks / Европейский парламент и Совет ЕС. — 2019 [Электронный ресурс] — Режим доступа: URL: `https://eur-lex.europa.eu/eli/reg/2019/787/oj` (дата обращения: 13.10.2026).
4. Автоматическая обработка текстов на естественном языке и компьютерная лингвистика / Е. И. Большакова [и др.]. — М. : МИЭМ, 2011. — 272 с.
5. Spearman C. The Proof and Measurement of Association between Two Things / C. Spearman // The American Journal of Psychology. — 1904. — Т. 15, № 1. — С. 72—101.
6. Волкова Л. Л. Об ассоциативных бинарных мерах близости документов: классификация и приложение к кластеризации / Л. Л. Волкова, Ю. В. Строганов // Новые информационные технологии в автоматизированных системах. — 2014. — № 17. — С. 421—432.
7. Development and Application of a Metric on Semantic Nets / R. Rada [и др.] // IEEE Transactions on Systems, Man, and Cybernetics. — 1989. — Т. 19, № 1. — С. 17—30.
8. Wu Z. Verb Semantics and Lexical Selection / Z. Wu, M. Palmer // Proceedings of the 32nd Annual Meeting of the Association for Computational Linguistics. — Лас-Крусес, США, 1994. — С. 133—138.

9. Resnik P. Using Information Content to Evaluate Semantic Similarity in a Taxonomy / P. Resnik // Proceedings of the 14th International Joint Conference on Artificial Intelligence (IJCAI-95). — Монреаль, Канада, 1995. — С. 448—453.

10. Lin D. An Information-Theoretic Definition of Similarity / D. Lin // Proceedings of the 15th International Conference on Machine Learning (ICML-98). — Мэдисон, США, 1998. — С. 296—304.

11. Shannon C. E. A Mathematical Theory of Communication / C. E. Shannon // Bell System Technical Journal. — 1948. — Т. 27, № 3. — С. 379—423.

12. Diakoulaki D. Determining Objective Weights in Multiple Criteria Problems: The CRITIC Method / D. Diakoulaki, G. Mavrotas, L. Papayannakis // Computers & Operations Research. — 1995. — Т. 22, № 7. — С. 763—770.

13. Methods and Metrics for Cold-Start Recommendations / A. I. Schein [и др.] // Proceedings of the 25th Annual International ACM SIGIR Conference. — Тампере, Финляндия, 2002. — С. 253—260.

14. Evaluating Collaborative Filtering Recommender Systems / J. L. Herlocker [и др.] // ACM Transactions on Information Systems. — 2004. — Т. 22, № 1. — С. 5—53.

15. Improving Recommendation Lists Through Topic Diversification / C.-N. Ziegler [и др.] // Proceedings of the 14th International Conference on World Wide Web (WWW '05). — Тиба, Япония, 2005. — С. 22—32.

16. Rocchio J. J. Relevance Feedback in Information Retrieval / J. J. Rocchio // The SMART Retrieval System: Experiments in Automatic Document Processing / под ред. G. Salton. — Энглвуд-Клиффс, США : Prentice-Hall, 1971. — С. 313—323.

17. Manning C. D. Introduction to Information Retrieval / C. D. Manning, P. Raghavan, H. Schütze. — Кембридж, Великобритания : Cambridge University Press, 2008. — 482 с.

18. Jannach D. Fast Computation of Query Relaxations for Knowledge-Based Recommenders / D. Jannach // AI Communications. — 2009. — Т. 22, № 4. — С. 235—248.

19. McSherry D. Similarity and Compromise / D. McSherry // Case-Based Reasoning Research and Development (ICCBR 2003). Lecture Notes in Computer Science, vol. 2689. — Берлин, Германия : Springer, 2003. — С. 291—305.

20. Фридл Д. Регулярные выражения / Д. Фридл. — 3-е изд. — СПб. : Символ-Плюс, 2008. — 608 с.